Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-7 «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ

НА ТЕМУ:

Метод обеспечения дифференциальной приватности при генерации синтетических данных

Студент ИУ7-84Б _____ Н. А. Турчанский
(группа) (подпись) (инициалы, фамилия)

Руководитель ВКР _____ А. Л. Исаев
(подпись) (инициалы, фамилия)

Нормоконтролер _____ _____
(подпись) (инициалы, фамилия)

2025 год

РЕФЕРАТ

Расчетно-пояснительная записка 53 с., 18 рис., 4 табл., 21 источн., 4 прил.

СИНТЕТИЧЕСКИЕ ДАННЫЕ, ДИФФЕРЕНЦИАЛЬНАЯ ПРИВАТНОСТЬ, ГЕНЕРАЦИЯ, СЕТИ, МЕХАНИЗМ, СТРУКТУРА

В данной работе представлена разработка метода обеспечения дифференциальной приватности при генерации синтетических данных.

Введены понятия предметной области синтетических данных и дифференциальной приватности. Проанализированы существующие методы генерации синтетических данных и дифференциальной приватности. Разработан программное обеспечение, реализующее разработанный метод. Исследованы характеристики разработанного метода.

СОДЕРЖАНИЕ

РЕФЕРАТ **2**

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ **5**

ВВЕДЕНИЕ **6**

1 Аналитическая часть **7**

1.1 Синтетические данные 7

1.2 Методы генерации синтетических данных 10

1.2.1 GAN 10

1.2.2 cGAN 13

1.2.3 ctGAN 14

1.2.4 VAE 15

1.2.5 Байесовские сети 16

1.2.6 Сравнение методов 17

1.3 Дифференциальная приватность 18

1.3.1 Теоретические основы дифференциальной приватности . 19

1.4 Типы приватности 20

1.4.1 ε – дифференцированная приватность 20

1.4.2 (ε, δ) – дифференцированная приватность 20

1.5 Механизмы приватности 21

1.5.1 Механизм Лапласа 21

1.5.2 Механизм Гаусса 21

1.5.3 Экспоненциальный механизм 22

1.5.4 Сравнение механизмов 23

1.6 Формализация задачи 23

1.6.1 Идея комбинированного метода 23

2 Конструкторская часть **25**

2.1 Архитектура метода 25

2.2 Предварительная обработка данных 25

2.3 Построение структуры БС с ДП 28

2.4 Генерация синтетических данных 30

2.5 Особенности реализации 31

3 Технологическая часть 33
3.1 Выбор средств программной реализации 33
3.2 Реализация программного обеспечения 33
3.3 Основные модули 35
3.4 Реализация алгоритма построения БС с ДП 37
3.5 Формат входных и выходных данных 39
3.6 Тестирование программного обеспечения 40
3.7 Пример пользовательского интерфейса 41

4 Исследовательская часть 42
4.1 Технические характеристики 42
4.2 Методика исследования 42
4.3 Исследование характеристик 43
4.3.1 Время работы 43
4.3.2 Качество данных 47
4.4 Сравнение с альтернативными методами 47
4.5 Выводы 49

ЗАКЛЮЧЕНИЕ 50

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 52

ПРИЛОЖЕНИЕ А 53

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

1. БС — Байесовская сеть;

2. ДП — дифференциальная приватность.

ВВЕДЕНИЕ

В эпоху цифровой трансформации данные стали ключевым ресурсом для анализа, машинного обучения и принятия решений. Однако использование реальных данных, особенно в чувствительных областях (медицина, финансы, персональная аналитика), сталкивается с проблемами конфиденциальности и законодательных ограничений, таких как GDPR и ФЗ-152 «О персональных данных». [1; 2]

Цель выпускной квалификационной работы — разработка метода обеспечения дифференциальной приватности при генерации синтетических данных.

Для достижения поставленной цели необходимо решить следующие задачи:

— проанализировать и классифицировать существующие методы генерации синтетических данных и дифференциальной приватности;

— сформулировать концепцию комбинированного метода на уровне идеи, формализовать задачу в виде функциональной модели;

— выделить ключевые этапы разрабатываемого метода и описать их в виде детализированной диаграммы IDEF0 и схем алгоритмов;

— разработать программное обеспечение, реализующее разработанный метод;

— исследовать характеристики разработанного метода при различных входных данных;

— провести сравнение результатов работы реализованного метода с альтернативными методами.

1 Аналитическая часть

1.1 Синтетические данные

Синтетические данные — это сгенерированные компьютером данные, обладающие теми же характеристиками и статистическими свойствами, что и реальные данные. Они применяются в том случае, если получение реальных данных затруднено, требует больших затрат, ставит под угрозу конфиденциальность пользователей или занимает слишком много времени. Синтетические данные могут быть текстовыми или табличными, а также представлять собой видео, изображения или звуки, как и реальные данные. [3]

Математически синтетические данные можно определить как выборку $X_{syn} = \{x_1, x_2, ..., x_n\}$ из некоторого распределения P_{syn}, которое аппроксимирует исходное распределение реальных данных P_{real}. Цель генерации синтетических данных заключается в минимизации расхождения между этими распределениями, которую описывают формулой (1.1):

$$\min_{P_{syn}} D(P_{real}||P_{syn}), \tag{1.1}$$

где:

— $D(P_{real}||P_{syn})$ — мера расхождения между распределениями.

Важным аспектом синтетических данных является их способность сохранять статистические свойства исходных данных. [4]

Это достигается через моделирование совместного распределения всех признаков по формуле (1.2):

$$P(X_1, X_2, ..., X_d) = \prod_{i=1}^{d} P(X_i|X_1, ..., X_{i-1}), \tag{1.2}$$

где:

— d — размерность данных, где каждый условный множитель может быть смоделирован различными методами.

Синтетические данные разделяют на три категории:

— Полностью синтетические данные, которые не имеют с реальными данными почти ничего общего и генерируются на основе некоторых признаков

реальных данных. Они сохраняют статистические свойства реальных данных и фактически заменяют их. [3; 4]

— Частично синтетические данные, которые заменяют только некоторые значения в реальных данных, если они являются конфиденциальными или содержат пропуски. [3; 4]

— Гибридные синтетические данные, которые генерируются с использованием и реальных, и полностью синтетических данных: для реальных данных выбираются близкие им синтетические, и они объединяются, формируя гибридные данные. [3; 4]

Категориальные признаки

Важную роль при генерации синтетических данных играют категориальные признаки, которые являются переменными, принимающими ограниченное число значений (например, пол, страна, тип товара). Категориальные признаки позволяют выразить свойства и разбить данные на группы. [5]

Математически категориальная переменная X может быть представлена как случайная величина, принимающая значения из конечного множества $C = \{c_1, c_2, ..., c_k\}$ с вероятностями $P(X = c_i) = p_i$, где $\sum_{i=1}^{k} p_i = 1$.

Для многомерного случая с m категориальными признаками совместное распределение описывается по формуле (1.3):

$$P(X_1 = c_{1,i_1}, X_2 = c_{2,i_2}, ..., X_m = c_{m,i_m}) = p_{i_1,i_2,...,i_m}, \tag{1.3}$$

где:

— $p_{i_1,i_2,...,i_m}$ — совместная вероятность соответствующей комбинации категорий.

Категориальные признаки разделяют на три типа:

— Дискретные — численные значения из конечного или счётного множества (например, количество комнат в квартире: $\{1, 2, 3, \dots\}$)

— Номинативные — нет порядка (например, цвет: красный, синий, зелёный);

— Порядковые — есть иерархия (например, уровень образования: школа, бакалавр, магистр);

— Бинарные — два значения (например, да/нет).

Корреляция

Корреляция в контексте генерации синтетических данных — это статистическая взаимосвязь между признаками, которую необходимо сохранить, чтобы искусственные данные оставались реалистичными и пригодными для анализа или машинного обучения. Если синтетические данные игнорируют связи, то неизбежны нереалистичные комбинации, снижение точности моделей, ошибки в анализах [5].

Корреляция между двумя числовыми переменными X и Y определяется как (1.4):

$$\rho_{X,Y} = \frac{\operatorname{cov}(X, Y)}{\sigma_X \sigma_Y}, \tag{1.4}$$

где:

— σ_X, σ_Y — стандартные отклонения.

Фробениусова норма

Фробениусова норма — это ключевая метрика в линейной алгебре и машинном обучении, используемая для оценки размера матриц и ошибок между ними. В контексте генерации синтетических данных она измеряет, насколько синтетические данные отклоняются от реальных.

Для матрицы $A \in \mathbb{R}^{m \times n}$ Фробениусова норма высчитывается по формуле (1.5):

$$\|A\|_F = \sqrt{\sum_{i=1}^{m} \sum_{j=1}^{n} |a_{ij}|^2}, \tag{1.5}$$

где:

— a_{ij} — элементы матрицы.

Для оценки качества синтетических данных, сгенерированных на основе исходных данных используется формула (1.6):

$$\varepsilon = \|P - \hat{P}\|_F = \sqrt{\sum_{i,j}(p_{ij} - \hat{p}_{ij})^2}, \tag{1.6}$$

где:

— P — матрица распределения исходных данных;

— $\hat{P}$ — матрица синтетических данных.

1.2 Методы генерации синтетических данных

Создание синтетических данных включает в себя различные методы и подходы, которые позволяют генерировать данные, максимально приближенные к реальным по своим характеристикам и структуре [6].

1.2.1 GAN

Генеративные состязательные нейросети — это класс алгоритмов искусственного интеллекта, используемых в машинном обучении без вмешательства человека, реализованных системой двух нейронных сетей, конкурирующих друг с другом в игровой среде с нулевой суммой. [6]

Математическая основа GAN заключается в решении задачи минимакса. Пусть $p_{data}(x)$ — распределение реальных данных, $p_z(z)$ — распределение шума, $G(z;\theta_g)$ — генератор с параметрами θ_g, $D(x;\theta_d)$ — дискриминатор с параметрами θ_d.

Тогда целевую функцию GAN можно определить формулой (1.7):

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{data}(x)}[\ln D(x)] + \mathbb{E}_{z\sim p_z(z)}[\ln(1 - D(G(z)))], \tag{1.7}$$

В системе GAN одна генеративная сеть G генерирует синтетические образцы, а другая сеть — дискриминативная D, старается отличить правильные («оригинальные») образцы от неправильных (синтетических). [7]

Используя шум на входе, генеративная сеть G создает новый образец, смешав несколько исходных образцов. Цель генератора можно описать выражением (1.8)

$$\min_G \ln\{1 - D[G(z)]\}, \tag{1.8}$$

где:

— D — функция дискриминатора;

— G — функция генератора;

— z — входные параметры.

Дискриминативная сеть D обучается различать подлинные и поддельные образцы, а результаты различения подаются на вход генеративной сети так, чтобы она смогла подобрать лучший набор параметров и дискриминативная сеть уже не смогла бы отличить подлинные образцы от поддельных. [7]

При этом сеть D, анализируя образцы из оригинальных и синтетических данных, достигает некоторой точности различения. Постепенно синтетические образцы на выходе генеративной сети становятся все более качественными. Цель дискриминатора D можно описать формулой (1.9):

$$\max_D\{\ln D(x_t) + \ln(1 - D[x_f])\}, \tag{1.9}$$

где:

— x_t — исходные данные;

— x_f — сгенерированный образец.

Таким образом, алгоритм представляет собой минимаксную состязание для двух нейронных сетей, которое можно описать формулой (1.10):

$$\min_G \max_D\{\ln D(x_t) + \ln(1 - D[G(z)])\}, \tag{1.10}$$

Для синтезации данных необходимо данные от генератора не только подавать на дискриминатор, но и складывать их в отдельную базу, особенно в фазе обучения, близкой к достижению минимаксного состояния равновесия. В этом случае получится множество данных, очень близких к оригинальным, которые и являются искомыми синтетическими данными. [7]

Структура сети GAN представлена на рисунке 1.1



Рисунок 1.1 – Структура сети GAN

Структурная схема GAN, модифицированная для генерации синтетических данных, представлена на рисунке 1.2.

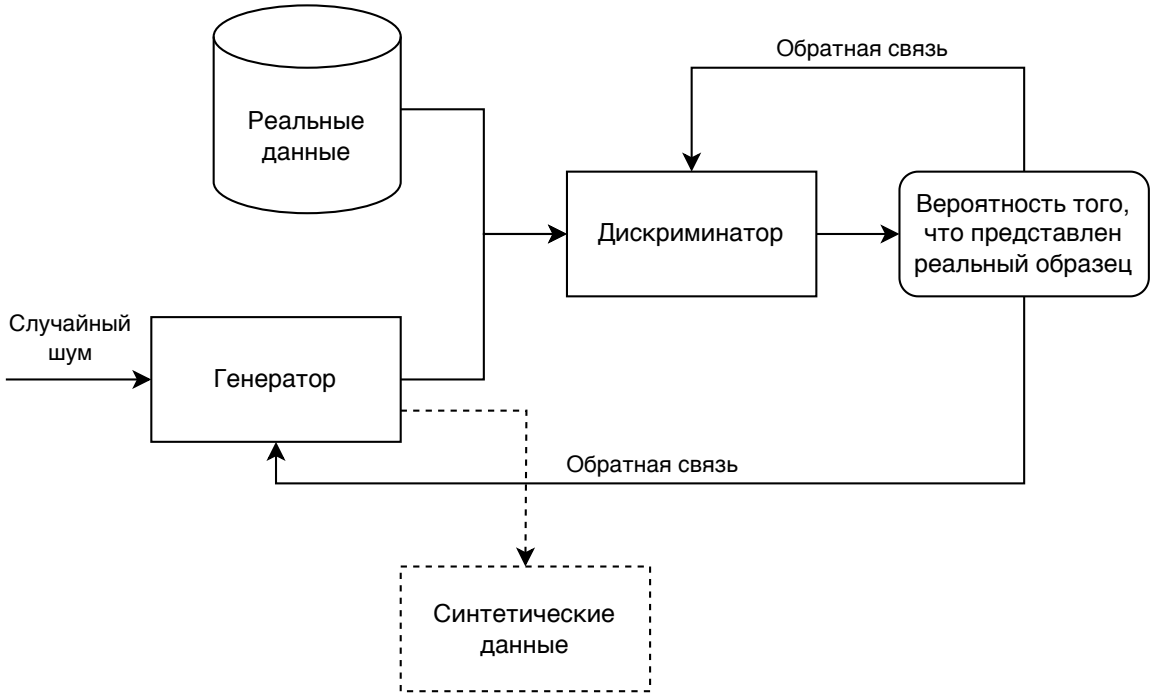


Рисунок 1.2 – Структурная схема GAN, модифицированная для генерации синтетических данных

1.2.2 cGAN

Основное отличие cGAN (conditional GAN) от классической GAN заключается в том, что на дискриминатор и генератор в качестве дополнительного входного слоя подается дополнительный параметр y, который может являться условием при генерации. [8]

Математически cGAN можно представить формулой (1.11):

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{data}(x)}[\ln D(x|y)] + \mathbb{E}_{z\sim p_z(z)}[\ln(1 - D(G(z|y)))], \quad (1.11)$$

где:

— y — условная информация (метки классов, атрибуты).

Генератор и дискриминатор принимают условную информацию различными способами:

— Конкатенация — условие просто добавляется к входному вектору;

— Условная нормализация — параметры нормализации зависят от условия;

— Attention механизмы — условие влияет на веса внимания.

На вход генератора подаются случайный шум и информация, которые объединяются в совместное входные параметры, в результате чего состязательная система обучения позволяет проявлять большую гибкость.

Структурная схема cGAN представлена на рисунке 1.3.

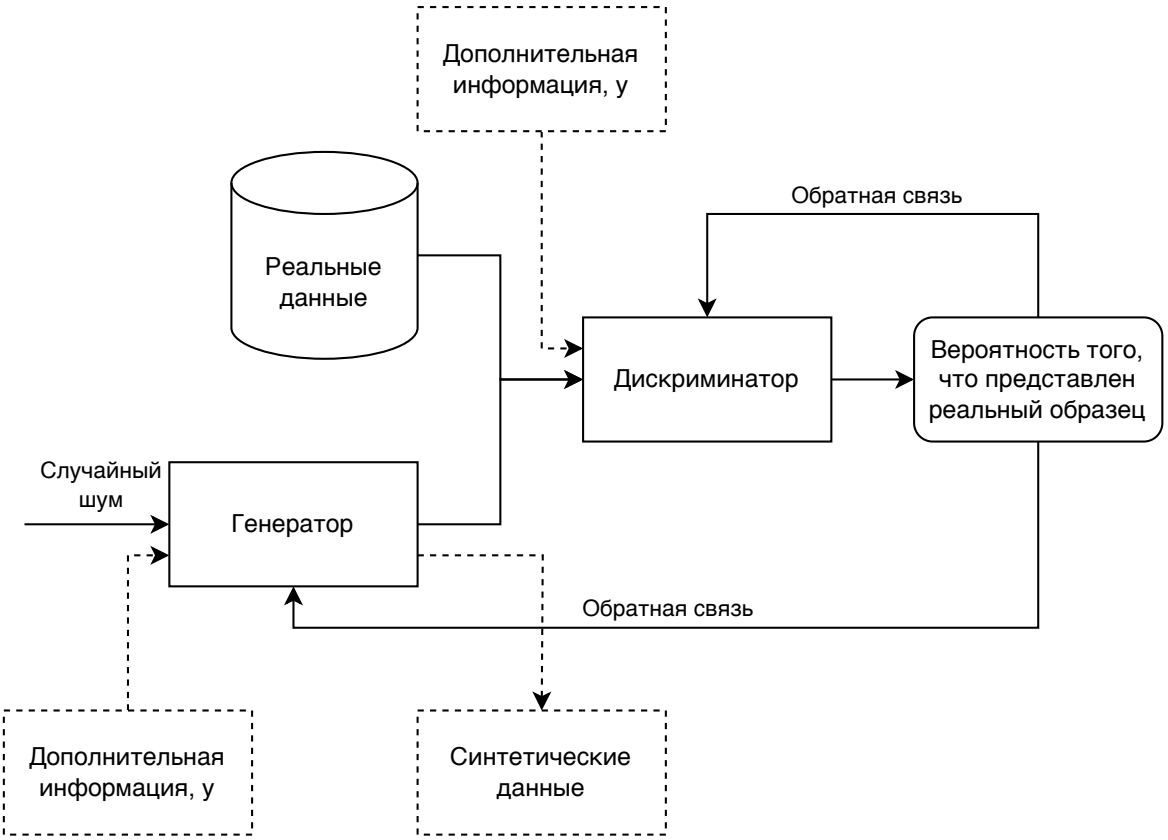


Рисунок 1.3 – Структурная схема cGAN

1.2.3 ctGAN

В традиционных GAN генератор повторяет распределение реальных данных. В случае дисбаланса в категориальных колонках, если при обучении данные выбираются случайным образом, то строки не будут представлены в достаточной степени и, следовательно, генератор может быть обучен неправильно. Для решения этих проблем была предложена архитектура cGAN, адаптированная для генерации равномерно распределенных многомодальных табличных данных, названная ctGAN (conditional tabular GAN). [9]

Задача генератора ctGAN состоит в том, чтобы все категории из дискретных атрибутов были равномерно отобраны в процессе обучения, а во время тестирования было восстановлено реальное распределение данных. [10]

Алгоритм ctGAN включает следующие этапы:

1. Предобработка данных: анализ каждого столбца для определения типа (непрерывный/дискретный);

2. Условная выборка: выбор дискретного столбца col_i с вероятностью пропорциональной логарифму числа уникальных значений, выбор конкретного значения val_j из столбца равномерно, выборка строк, содержащих выбранное значение;

3. Генерация условного вектора: создание маски m для указания условного столбца, формирование вектора условий c.

Математически процесс генерации можно записать по формуле (1.12):

$$x_{syn} = G(z, c, m), \tag{1.12}$$

где:

— $z \sim \mathcal{N}(0, I)$ — случайный шум;

— c — условный вектор;

— m — маска.

1.2.4 VAE

Вариационные автокодировщики (VAE) представляют собой генеративные модели, основанные на принципах вариационного вывода и теории информации. VAE состоит из двух основных компонентов: кодировщика (encoder) и декодировщика (decoder). [11]

Математическая формулировка VAE основана на максимизации нижней границы логарифма правдоподобия данных и представляется выражением (1.13):

$$\ln p(x) \geqslant \mathbb{E}_{q_\phi(z|x)}[\ln p_\theta(x|z)] - KL(q_\phi(z|x)||p(z)), \tag{1.13}$$

где:

— $q_\phi(z|x)$ — приближенное апостериорное распределение (кодировщик);

— $p_\theta(x|z)$ — декодер;

— $p(z)$ — априорное распределение (обычно стандартное нормальное);

— KL — дивергенция Кульбака-Лейблера.

1.2.5 Байесовские сети

Статистические и вероятностные методы представляют собой фундаментальный подход к генерации синтетических данных, основанный на математическом моделировании распределений реальных данных. [5]

Основные принципы статистических методов:

— оценка параметров распределения — по исходным данным оцениваются параметры теоретического распределения;

— валидация модели — проверка соответствия выбранной модели данным;

— генерация новых выборок — использование оцененных параметров для создания синтетических данных.

Для многомерных данных часто используется предположение о независимости признаков:

$$p(\mathbf{x}) = \prod_{i=1}^{d} p(x_i), \tag{1.14}$$

Байесовские сети — это тип вероятностной графической модели, которая представляет отношения между переменными с использованием ориентированного ациклического графа. [5]

В Байесовских сетях:

1. узлы соответствуют случайным переменным;

2. дуги отражают причинно-следственные связи;

3. каждому узлу сопоставлено условное распределение вероятностей.

Математическая основа Байесовских сетей базируется на разложении совместного распределения по формуле (1.15):

$$P(X_1, X_2, ..., X_n) = \prod_{i=1}^{n} P(X_i|Pa(X_i)), \tag{1.15}$$

где:

— $Pa(X_i)$ — родительские узлы для узла X_i.

Процесс обучения байесовской сети включает структурное обучение: определение графа зависимостей, поиск на основе оценок, тестирование условной независимости, жадные алгоритмы и эволюционные подходы; параметрическое обучение: оценка условных распределений, максимальное правдоподобие, байесовский подход с априорными распределениями [12].

Для генерации синтетических данных используется прямая выборка (1.16):

$$x_i \sim P(X_i|pa(x_i)), \tag{1.16}$$

где:

— $pa(x_i)$ — значения родительских узлов.

1.2.6 Сравнение методов

Сравнение методов генерации синтетических данных представлено в таблице 1.1:

— 1 — тип данных. Возможность метода те или иные типы данных;

— 2 — сложность обучения, где E — эпохи; N — слои; B — батч; Z — число узлов; D — количество зависимостей;

— 3 — качество сохранения корреляций между признаками по Фробениусовой норме;

— 4 — модификация для ДП. Возможности модификации алгоритма для обеспечения ДП.

Таблица 1.1 – Сравнение методов генерации синтетических данных

Метод	1	2	3	4
GAN	Изображение	$O(E \cdot N \cdot B)$	0.07	DP-SGD при обучении дискриминатора
cGAN	Изображение	$O(E \cdot N \cdot B)$	0.07	DP-SGD для защиты приватности условных меток
ctGAN	Табличные данные	$O(E \cdot N \cdot B)$	0.06	DP-SGD для добавления шума к трансформированным данным
VAE	Дискретные данные	$O(E \cdot N \cdot B)$	0.11	DP-SGD при обучении энкодера и декодера
БС	Табличные данные	$O(Z \cdot D)$	0.07	Добавление шума к частотным таблицам

1.3 Дифференциальная приватность

Дифференциальная приватность — это математическая концепция, которая обеспечивает информационно-теоретическую гарантию конфиденциальности. Стандартным способом реализации дифференциальной конфиденциальности является введение достаточного количества шума в данные.

Однако в дополнение к другим ограничениям дифференциальной конфиденциальности этот процесс добавления шума влияет на точность и полезность данных, но минимизирует влияние индивидуальных записей на результаты статистических запросов. [13]

1.3.1 Теоретические основы дифференциальной приватности

Дифференциальная приватность базируется на принципе неразличимости: результаты анализа не должны позволять определить, участвовал ли конкретный индивид в исследовании или нет. Этот принцип формализуется через понятие соседних наборов данных.

Два набора данных D и D' называются соседними, если они отличаются записью ровно одного индивида $|D \triangle D'| = 1$, где $\triangle$ обозначает симметрическую разность множеств.

Дифференциальная приватность обеспечивает защиту личной информации, гарантируя, что результаты анализа не позволят точно определить информацию о конкретных индивидах. В рамках ДП данные обрабатываются с добавлением шума, что минимизирует влияние индивидуальных записей на результаты статистических запросов.

Таким образом, как показано на рисунке 1.4, даже если в набор данных добавляется или исключается информация о конкретном индивиде, это не влияет на общие выводы о группе. [14]

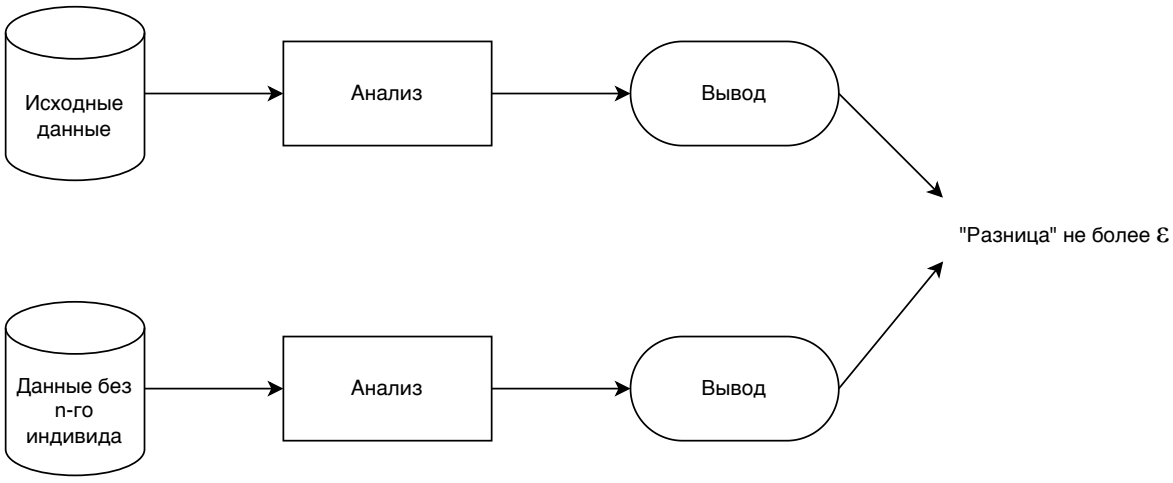


Рисунок 1.4 – Принцип дифференциальной приватности

1.4 Типы приватности

Параметр приватности ε — это неотрицательное значение, определяющее уровень приватности, который влияет на количество добавляемого шума. [15]

Интуитивная интерпретация параметра ε:

— $\varepsilon = 0$ — идеальная приватность (бесконечный шум)

— $\varepsilon \to \infty$ — отсутствие приватности

— $\varepsilon \in (0, 1]$ — строгая приватность

— $\varepsilon \in (1, 10]$ — умеренная приватность

— $\varepsilon > 10$ — слабая приватность

1.4.1 ε – дифференцированная приватность

Модель ε – дифференцированной приватности гарантирует, что результаты анализа данных не изменятся значительно, если одна запись будет добавлена или удалена. [15]

Механизм M обеспечивает ε – дифференциальную приватность, если для любых двух соседних наборов данных D и D' из множества S выполняется условие по формуле (1.17):

$$Pr[M(D) \in S] \leqslant \exp(\varepsilon) \times Pr[M(D') \in S], \tag{1.17}$$

где:

— ε — параметр приватности.

1.4.2 (ε, δ) – дифференцированная приватность

Модель (ε, δ) – дифференцированной приватности вводит дополнительный параметр δ, который ослабляет строгие гарантии приватности. Параметр δ определяет вероятность того, что гарантия приватности будет нарушена в некоторых случаях. Это дает гибкость в балансе между приватностью и точностью результатов. [15]

Механизм M обеспечивает (ε, δ) – дифференциальную приватность, если для любых двух соседних наборов данных D и D' (различающихся на одну запись) выполняется условие по формуле (1.18):

$$Pr[M(D) \in S] \leqslant \exp(\varepsilon) \times Pr[M(D') \in S] + \delta, \tag{1.18}$$

где:

— ε — параметр приватности;

— δ — параметр вероятности нарушения приватности.

1.5 Механизмы приватности

1.5.1 Механизм Лапласа

Лапласов механизм добавляет к результату запроса шум, сгенерированный из распределения Лапласа [16].

Результат Лапласова механизма вычисляется по формуле (1.19):

$$M'(D) = f(D) + \mathrm{Lap}\left(0, \frac{\Delta f}{\varepsilon}\right), \tag{1.19}$$

где:

— Δf — глобальная чувствительность функции f;

— ε — параметр приватности.

1.5.2 Механизм Гаусса

Гауссов механизм похож на Лапласов, но шум добавляется на основе нормального (Гауссова) распределения. [16] К результатам запроса добавляется шум по формуле (1.20):

$$M'(D) = f(D) + \mathcal{N}(0, \sigma^2), \tag{1.20}$$

где:

— $\mathcal{N}(0, \sigma^2)$ — многомерное нормальное распределение.

Для обеспечения (ε, δ)-дифференциальной приватности параметр σ вычисляется по формуле (1.21):

$$\sigma = \frac{\Delta_2 f \sqrt{2 \ln(1.25/\delta)}}{\varepsilon}, \tag{1.21}$$

где:

— $\Delta_2 f$ — L_2-чувствительность функции.

1.5.3 Экспоненциальный механизм

Экспоненциальный механизм работает путем добавления случайности в процесс выбора элементов, где вероятность выбора каждого элемента зависит от его качества (оценки полезности) и параметра приватности. [16]

Пусть $\mathcal{R}$ — множество возможных выходов, $u : \mathcal{D} \times \mathcal{R} \to \mathbb{R}$ — функция полезности. Экспоненциальный механизм выбирает выход $r \in \mathcal{R}$ с вероятностью пропорциональной:

$$P[M(D)] \propto \exp\left(\frac{\varepsilon u(D, r)}{2\Delta u}\right), \tag{1.22}$$

где:

— Δu — чувствительность функции полезности, вычислемая по формуле (1.23):

$$\Delta u = \max_{r \in \mathcal{R}} \max_{D \sim D'} |u(D, r) - u(D', r)|, \tag{1.23}$$

Нормализованная вероятность:

$$P[M(D)] = \frac{\exp\left(\frac{\varepsilon u(D,r)}{2\Delta u}\right)}{\sum_{r' \in \mathcal{R}} \exp\left(\frac{\varepsilon u(D,r')}{2\Delta u}\right)}, \tag{1.24}$$

1.5.4 Сравнение механизмов

Сравнение механизмов дифференциальной приватности представлено в таблице 1.2:

— 1 — тип приватности. Тип приватности, который использует данный метод;

— 2 — тип данных. Типы данных, для которых подходит механизм;

— 3 — вычислительная сложность. Сложность применения механизма.

Таблица 1.2 – Сравнение механизмов дифференциальной приватности

Механизм	1	2	3
Лапласовский	$(\varepsilon, 0)$	Числовые	$O(1)$
Гауссовский	(ε, δ)	Числовые	$O(1)$
Экспоненциальнй	ε	Категориальные	$O(m)$

1.6 Формализация задачи

В ходе выполнения выпускной квалификационной работы необходимо разработать и реализовать метод, предоставляющий возможность генерировать синтетические данные с гарантиями дифференциальной приватности. Концепция метода заключается в совместном использовании метода генерации синтетических данных и метода дифференциальной приватности путем добавления шума на этапе генерации.

1.6.1 Идея комбинированного метода

Пусть $D = \{x_1, x_2, ..., x_n\}$ — исходная база данных, где каждая запись $x_i \in \mathbb{R}^d$ представляет собой d-мерный вектор признаков. Задача состоит в разработке метода $\mathcal{M}$, который:

— генерирует синтетические данные: $D_{syn} = \mathcal{M}(D) = \{y_1, y_2, ..., y_m\}$, где m — заданное количество синтетических записей;

— обеспечивает дифференциальную приватность: $\mathcal{M}$ удовлетворяет (ε, δ)-дифференциальной приватности;

— сохраняет полезность: синтетические данные сохраняют статистические свойства исходных данных.

Также метод должен быть реализован как приложение с пользовательским интерфейсом. На рисунке 1.5 представлена функциональная модель задачи в виде диаграммы IDEF0 нулевого уровня.

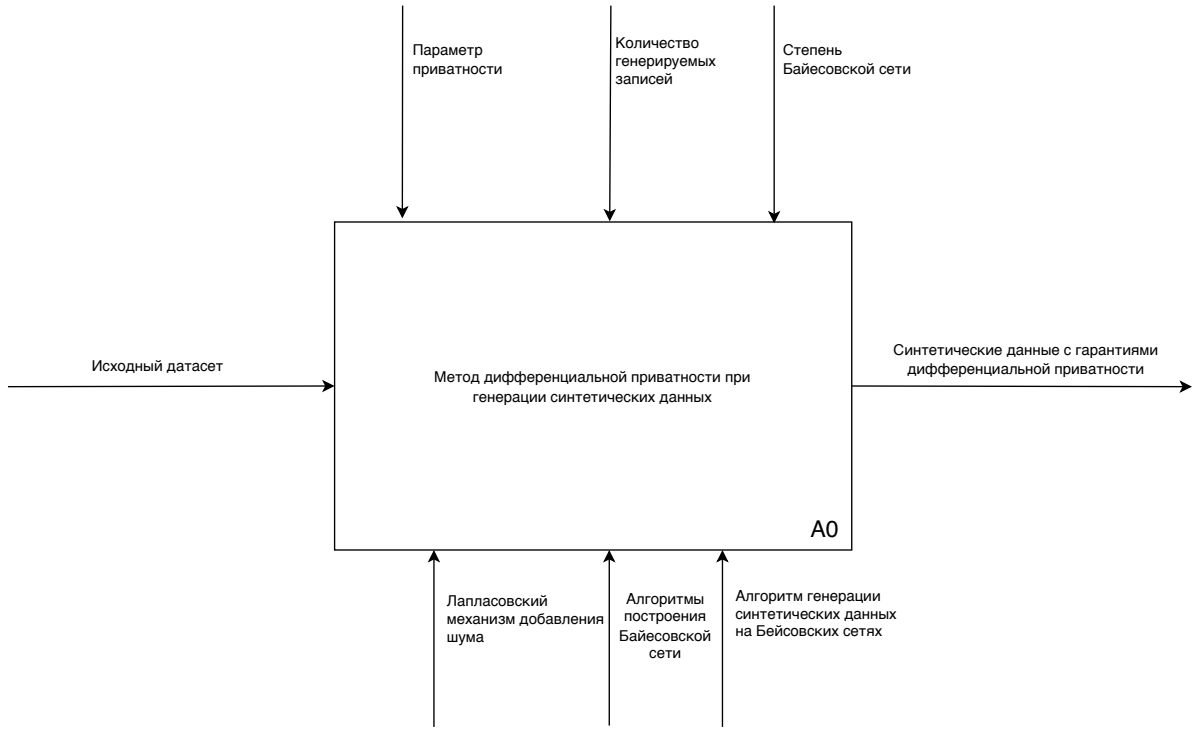


Рисунок 1.5 – Функциональная модель задачи

2 Конструкторская часть

2.1 Архитектура метода

Разрабатываемый метод обеспечения дифференциальной приватности при генерации синтетических данных основан на Байесовских сетях и состоит из трех основных этапов:

— предварительная обработка входных данных;

— построение структуры Байесовской сети с дифференциальной приватностью;

— генерация синтетических данных на основе построенной сети.

Архитектура системы представляет собой модульную структуру, где каждый компонент выполняет специфическую функцию в процессе генерации приватных синтетических данных.

На рисунке 2.1 представлена функциональная модель разрабатываемого метода.

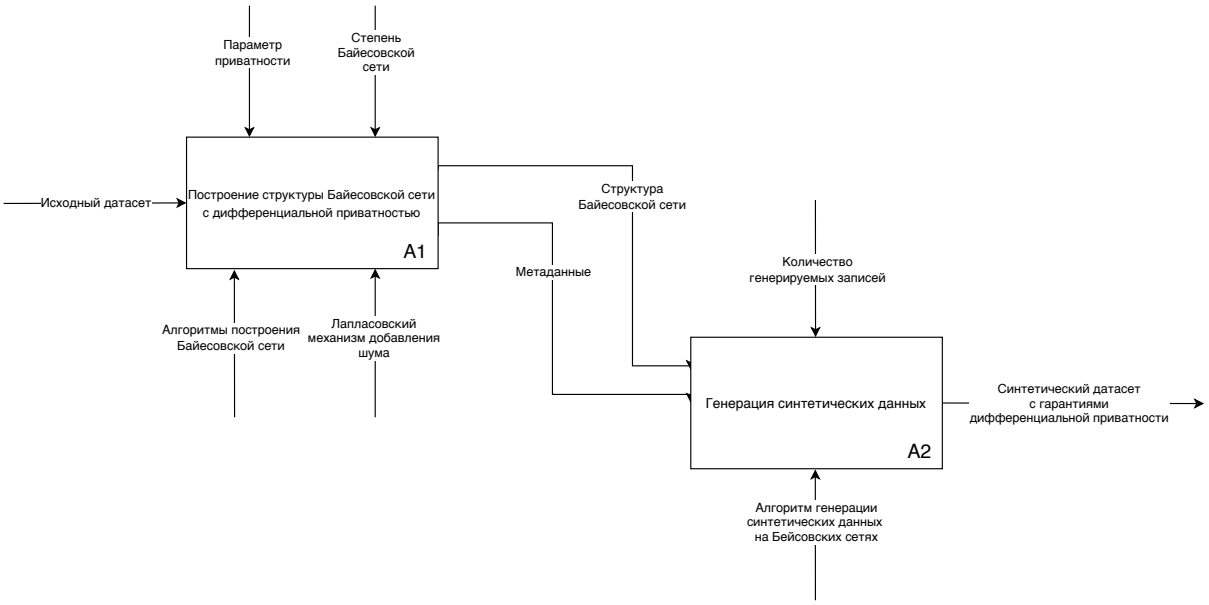


Рисунок 2.1 – Функциональная модель разрабатываемого метода

2.2 Предварительная обработка данных

Этап предварительной обработки является критически важным для качественной генерации синтетических данных. Система автоматически опре-

деляет типы данных и их характеристики, что обеспечивает корректную работу последующих алгоритмов.

Тип данных является важным компонентом домена атрибутов. Метод поддерживает пять типов данных:

— Integer — целые числа;

— Float — числа с плавающей точкой;

— String — строковые значения;

— DateTime — временные метки.

Система позволяет пользователям явно указывать типы данных. Если тип данных атрибута не указан пользователем, то метод выполняет автоматическое определение типа на основе анализа содержимого столбцов.

Алгоритм определения типа данных:

1. Проверка на числовой тип (Integer/Float);
2. Для нечисловых данных — проверка на DateTime;
3. Проверка на специальные форматы (SSN);
4. По умолчанию — String тип.

Тип данных атрибута ограничивает его домен, который может быть дополнительно ограничен, если атрибут категоричен. Например, в наборе данных студентов атрибут степени может принимать только значения $\{BS, BA, MS, PhD\}$. Атрибут считается категориальным, если во входном наборе данных наблюдается ограниченное количество различных значений для этого атрибута (по умолчанию не более 20 уникальных значений).

Математически категориальный признак определяется как:

$$\text{is_categorical}(A) = \begin{cases} \text{True}, & \text{если } |unique(A)| \leq threshold, \\ \text{False}, & \text{иначе}, \end{cases} \tag{2.1}$$

где:

— $unique(A)$ — множество уникальных значений атрибута A;

— $threshold$ — пороговое значение.

Этап предварительной обработки данных продемонстрирован на рисунке 2.2:

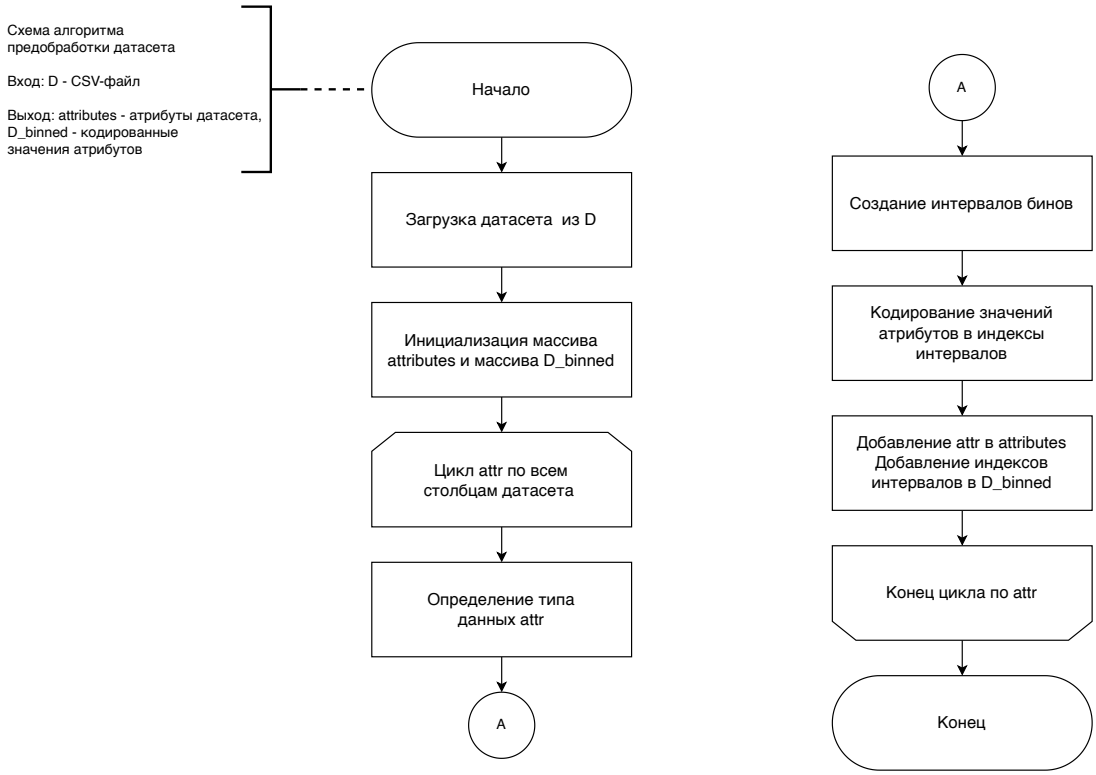


Рисунок 2.2 – Этап предварительной обработки данных

2.3 Построение структуры БС с ДП

Построение структуры Байесовской сети с дифференциальной приватностью является ключевым этапом разработанного метода. Алгоритм использует жадный подход для поиска оптимальной структуры сети.

Алгоритм строит БС $\mathcal{N}$ из входного набора данных D, атрибутов A и максимального количества родителей узла БС k.

В алгоритме:

— V — множество посещенных атрибутов;

— Π — подмножество V, которое станет родителями узла X;

— Ω — множество всех возможных пар (атрибут, родители).

Атрибуты Π определяются путем поиска максимального $I(X, \Pi)$, который вычисляется с добавлением шума Лапласа по формуле (2.2):

$$I(X_i; \Pi) = \sum_{x_i, \pi} P(x_i, \pi) \ln \frac{P(x_i, \pi)}{P(x_i)P(\pi)} + \mathrm{Lap}\left(\frac{\Delta I}{n\varepsilon}\right), \tag{2.2}$$

где:

— ε — параметр приватности;

— n — количество записей входных данных;

— ΔI — чувствительность взаимной информации.

Чувствительность взаимной информации вычисляется по формуле:

$$\Delta I = \frac{2 \ln(n+1)}{n}, \tag{2.3}$$

Схема алгоритма для построения структуры БС с ДП представлена на рисунке 2.3

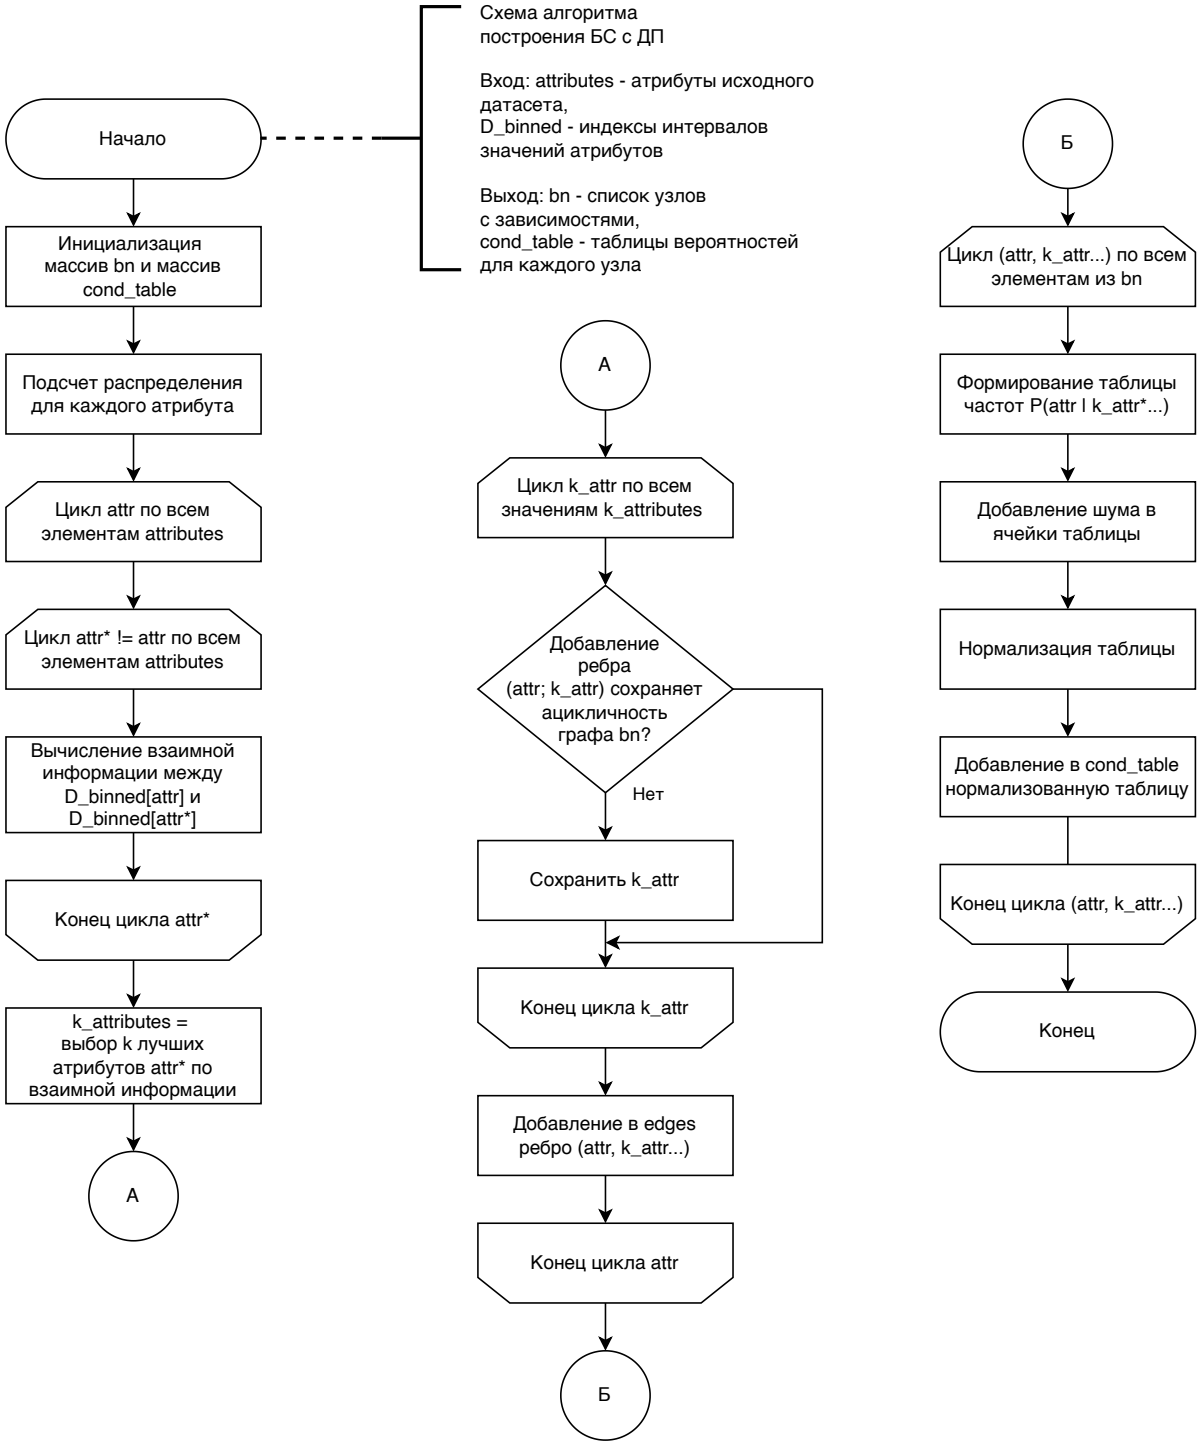


Рисунок 2.3 – Схема алгоритма для построения структуры БС с ДП

Для обеспечения дифференциальной приватности при выборе оптимальной структуры сети используется экспоненциальный механизм. Вероятность

выбора пары (X, Π) определяется по формуле (2.4):

$$P[(X, \Pi)] = \frac{\exp\left(\frac{\varepsilon \cdot I(X;\Pi)}{2\Delta I}\right)}{\sum_{(X',\Pi')\in\Omega} \exp\left(\frac{\varepsilon \cdot I(X';\Pi')}{2\Delta I}\right)}. \tag{2.4}$$

2.4 Генерация синтетических данных

После построения структуры Байесовской сети выполняется генерация синтетических данных. Процесс включает два основных этапа:

— построение приватных условных распределений;

— выборка данных из построенных распределений.

Для каждого узла в сети строится условное распределение $P(X_i|Parents(X_i))$ с добавлением шума Лапласа:

$$\tilde{N}(x_i, pa_i) = N(x_i, pa_i) + \mathrm{Lap}\left(\frac{k-1}{\varepsilon}\right), \tag{2.5}$$

где:

— $N(x_i, pa_i)$ — количество записей с значениями x_i и pa_i;

— k — количество атрибутов в сети.

На начальном этапе генерации метод читает построенную БС и метаданные атрибутов. Корневые атрибуты, которые не зависят от других переменных, сэмплируются из их безусловных распределений, а дочерние — из условных. Обход сети происходит в топологическом порядке.

Схема алгоритма генерации синтетических данных предаставлена на рисунке 2.4:

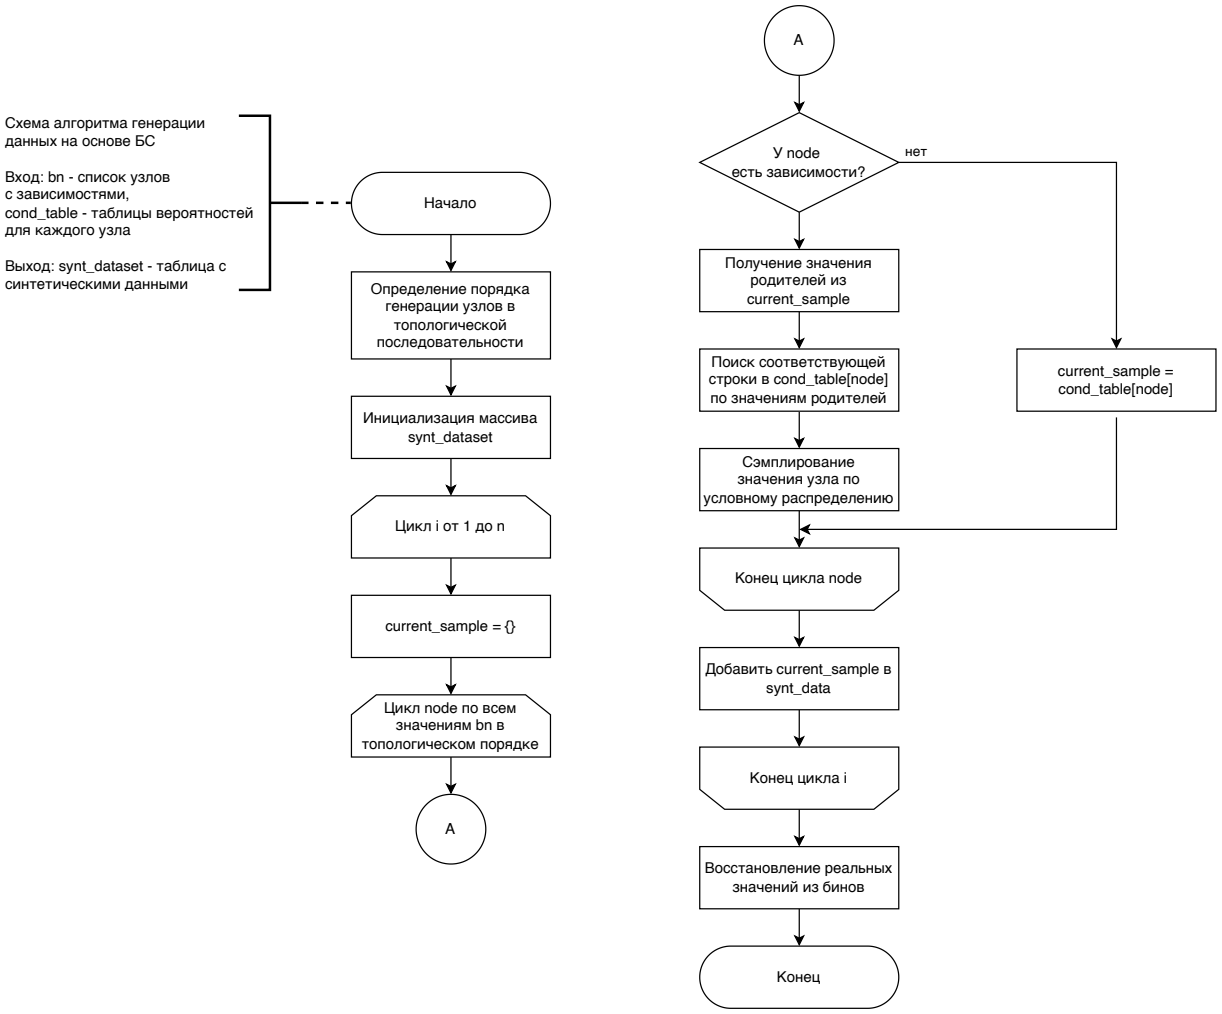


Рисунок 2.4 – Схема алгоритма генерации синтетических данных

2.5 Особенности реализации

Обработка категориальных атрибутов

Категориальные атрибуты кодируются в целочисленные значения для эффективной работы с Байесовской сетью:

$$encode(x_i) = \begin{cases} value_to_index[x_i], & \text{если атрибут категориальный,} \\ bin_index(x_i), & \text{если атрибут непрерывный.} \end{cases} \quad (2.6)$$

Обработка пропущенных значений

Пропущенные значения обрабатываются как отдельная категория с индексом $|domain| + 1$. Вероятность генерации пропущенного значения определяется по формуле:

$$P(\text{missing}) = \frac{count(\text{missing values})}{total_count}. \tag{2.7}$$

Постобработка результатов

После генерации закодированных значений выполняется их преобразование в исходный формат:

— декодирование категориальных значений;

— денормализация числовых значений;

— форматирование временных меток;

— генерация строковых значений заданной длины.

3 Технологическая часть

3.1 Выбор средств программной реализации

Выбор языка программирования

В качестве языка программирования был выбран Python так как:

— поддерживает библиотеки для анализа данных (pandas); [17]

— обладает инструментами для реализации машинного обучения (pytorch, catboost, scikit-learn); [18—20]

— обладает большим сообществом разработчиков и является одним из наиболее часто используемых языков в сфере машинного обучения.

Среда разработки

Для разработки программного обеспечения была выбрана интегрированная среда разработки (IDE) Visual Studio Code (VS Code), который обладает следующими преимуществами:

1. Производительность и низкое потребление ресурсов. VS Code отличается высокой скоростью работы и умеренным использованием системных ресурсов; [21]

2. Экосистема расширений. Магазин расширений (Extensions Marketplace) предоставляет доступ к множеству плагинов для кастомизации среды под конкретные нужды; [21]

3. Активное сообщество и регулярные обновления. VS Code разрабатывается Microsoft при поддержке open-source-сообщества, благодаря чему выходят частые обновления с новыми функциями и исправлениями багов. [21]

3.2 Реализация программного обеспечения

Реализованное программное обеспечение реализует метод дифференциальной приватности при генерации синтетических данных. Написанная

программа включает в себя компоненты, которые организованы в модули с разделением ответственности.

На рисунке 3.1 представлена диаграмма модулей.

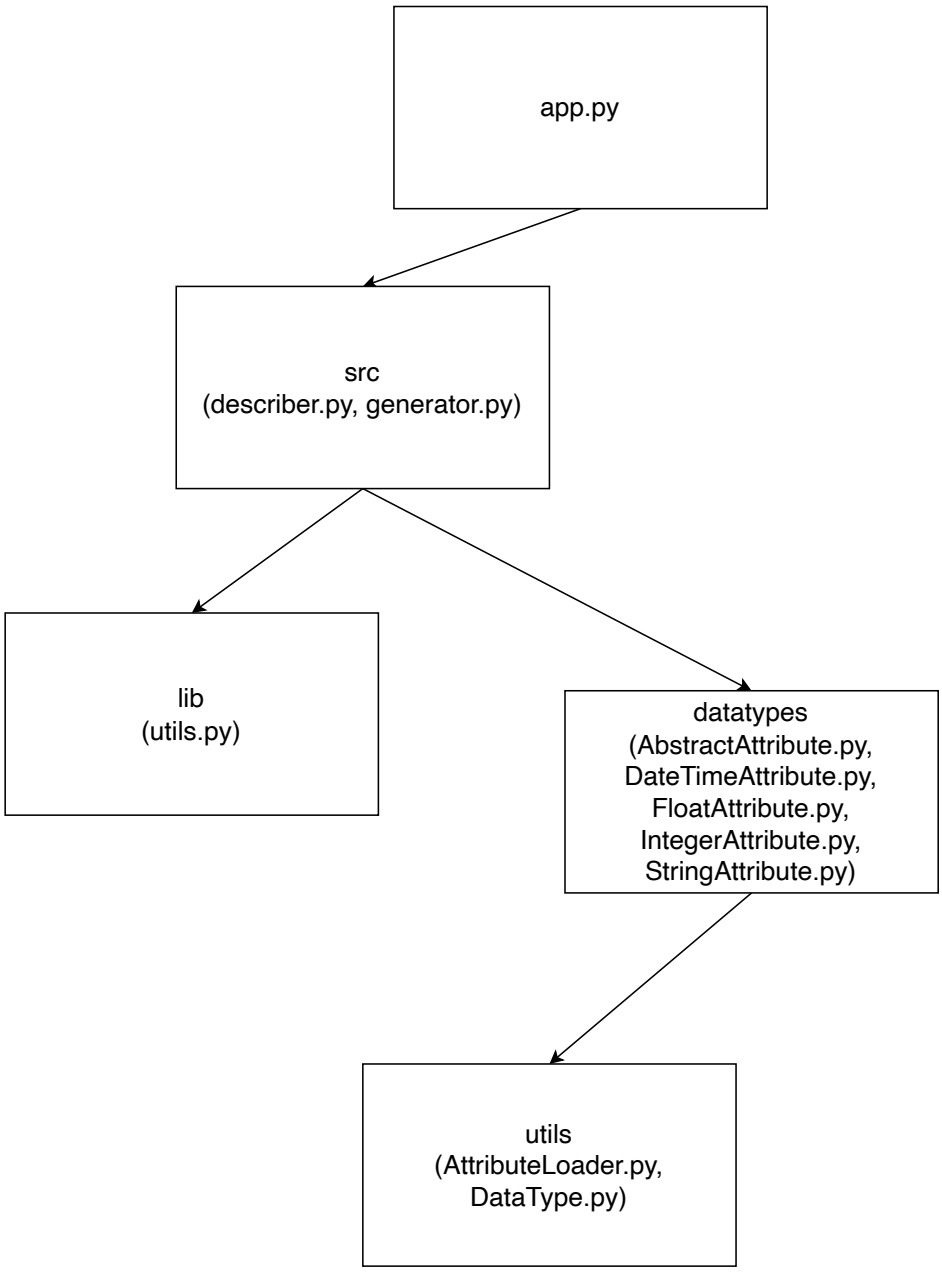


Рисунок 3.1 – Диаграмма модулей

3.3 Основные модули

Модуль src

Модуль src содержит реализацию алгоритма построения Байесовской сети с дифференциальной приватностью и отвечает за построение синтетических данных на основе ее структуры.

Класс Describer реализует методы:

— init — конструктор класс, к котором инициализируются атрибуты класса;

— describe_dataset — описывает датасет с использованием байесовской сети;

— read_dataset_from_csv — загружает датасет из CSV-файла;

— infer_attribute_data_types — определяет типы данных атрибутов;

— analyze_dataset_meta — анализирует метаинформацию датасета (ключи, категориальность и т.д.);

— is_categorical — определяет, является ли атрибут категориальным;

— represent_input_dataset_by_columns — представляет входной датасет в виде объектов-атрибутов;

— inject_laplace_noise_into_distribution_per_attribute — добавляет лапласовский шум в распределения атрибутов;

— encode_dataset_into_binning_indices — кодирует датасет в индексы бинов для построения байесовской сети.

— save_dataset_description_to_file — сохраняет описание датасета в файл.

Класс Generator реализует методы:

— init — онструктор класса. Инициализирует атрибуты экземпляра;

— generate_dataset — Генерирует синтетический датасет с учетом зависимостей между атрибутами;

— save_synthetic_data — Сохраняет сгенерированный синтетический датасет в файл;

— get_sampling_order — Возвращает порядок выборки атрибутов на основе структуры байесовской сети;

Модуль lib

Модуль lib содержит вспомогательные функции для работы модуля src. В данном модуле реализованы функции:

— calculate_sensitivity — вычисляет чувствительность для построения байесовской сети;

— calculate_delta — вычисляет параметр delta для применения дифференциальной приватности;

— calculate_k — вычисляет максимальную степень при построении байесовской сети;

— greedy_bayes — строит байесовскую сеть с помощью жадного алгоритма;

— exponential_mechanism — реализует экспоненциальный механизм для выбора структуры сети с учетом параметра приватности;

— set_random_seed — станавливает фиксированное значение seed для генераторов случайных чисел;

— mutual_information — вычисляет взаимную информацию между двумя распределениями (Series/DataFrame), используя mutual_info_score из sklearn;

— pairwise_attributes_mutual_information — вычисляет нормализованную взаимную информацию для всех пар признаков;

— normalize_given_distribution — нормализует переданный массив частот (преобразует в вероятностное распределение) и обрабатывает отрицательные и бесконечные значения;

— read_json_file — читает и возвращает содержимое JSON-файла.

3.4 Реализация алгоритма построения БС с ДП

Реализация алгоритма для построения структуры Байесовской сети с дифференциальной приватностью представлена на листинге 3.1.

Листинг 3.1 – Реализация алгоритма для построения структуры Байесовской сети с дифференциальной приватностью — часть 1

```
def bayes_struct(dataset: DataFrame, k: int, epsilon: float, seed=0):
    set_random_seed(seed)
    dataset: DataFrame = dataset.astype(str, copy=False)
    num_tuples, num_attributes = dataset.shape
    if not k:
        k = calculate_k(num_attributes, num_tuples)

    attr_to_is_binary = {attr: dataset[attr].unique().size <= 2 for attr
    in dataset}

    root_attribute = random.choice(dataset.columns)
    V = [root_attribute]
    rest_attributes = list(dataset.columns)
    rest_attributes.remove(root_attribute)
    print(f'Adding ROOT {root_attribute}')
    N = []
    while rest_attributes:
        parents_pair_list = []
        mutual_info_list = []
        num_parents = min(len(V), k)
        tasks = [(child, V, num_parents, split, dataset) for child,
    split in
                 product(rest_attributes, range(len(V) - num_parents +
    1))]
        with Pool() as pool:
            res_list = pool.map(worker, tasks)

        for res in res_list:
            parents_pair_list += res[0]
            mutual_info_list += res[1]

        if epsilon:
            sampling_distribution = exponential_mechanism(
        epsilon,
        mutual_info_list,
        parents_pair_list,
        attr_to_is_binary,
                num_tuples,
        num_attributes
        )
```

Листинг 3.2 – Реализация алгоритма для построения структуры Байесовской сети с дифференциальной приватностью — часть 2

```
                    idx =
    np.random.choice(list(range(len(mutual_info_list))),
    p=sampling_distribution)
     else:
              idx = mutual_info_list.index(max(mutual_info_list))

         N.append(parents_pair_list[idx])
         adding_attribute = parents_pair_list[idx][0]
         V.append(adding_attribute)
         rest_attributes.remove(adding_attribute)
         print(f'Adding attribute {adding_attribute}')

     return N
```

Реализация алгоритма генерации синтетических данных на основе Байесовской сети представлена на листинге 3.3.

Листинг 3.3 – Реализация алгоритма генерации синтетических данных на основе Байесовской сети

```
def generate_dataset(self, n, description_file, seed=0):
    set_random_seed(seed)
    self.n = n
    self.description = read_json_file(description_file)

    all_attributes = self.description['meta']['all_attributes']
    candidate_keys = set(self.description['meta']['candidate_keys'])
    self.encoded_dataset =
    DataGenerator.generate_encoded_dataset(self.n, self.description)
    self.synthetic_dataset = DataFrame(columns=all_attributes)
    for attr in all_attributes:
        attr_info = self.description['attribute_description'][attr]
        column = parse_json(attr_info)

        if attr in self.encoded_dataset:
            self.synthetic_dataset[attr] =
    column.sample_values_from_binning_indices(self.encoded_dataset[attr])
        elif attr in candidate_keys:
            self.synthetic_dataset[attr] =
    column.generate_values_as_candidate_key(n)
        else:
            binning_indices =
    column.sample_binning_indices_in_independent_attribute_mode(n)
            self.synthetic_dataset[attr] =
    column.sample_values_from_binning_indices(binning_indices)
```

3.5 Формат входных и выходных данных

Входные данные

Входными данными для разработанного методы являются:

1. датасет с исходными данными — CSV-файл с названиями атрибутов в формате на листинге 3.4:
2. настройки приватности — числовой параметр ϵ, который учитывется при добавлении шума;
3. количество генерируемых записей — числовой параметр, который учитывается непосредственно при генерации синтетических данных;
4. категориальные атрибуты — строковый параметр, в котором через запятую перечисляются названия атрибутов, являющихся категориальными;
5. количество родительских узлов — параметр, который учитывается при построении Байесовской сети.

Листинг 3.4 – CSV-файл с названиями атрибутов

```
age,education,sex,relationship,marital-status,income
19,HS-grad,Female,Not-in-family,Never-married,<=50K
35,HS-grad,Female,Unmarried,Never-married,<=50K
36,Bachelors,Male,Husband,Married-civ-spouse,>50K
40,Assoc-acdm,Male,Not-in-family,Divorced,>50K
36,Masters,Male,Husband,Married-civ-spouse,>50K
30,11th,Male,Husband,Married-civ-spouse,<=50K
44,Bachelors,Male,Husband,Married-civ-spouse,<=50K
37,Assoc-acdm,Male,Husband,Married-civ-spouse,>50K
36,Prof-school,Male,Not-in-family,Never-married,<=50K
50,10th,Male,Husband,Married-civ-spouse,<=50K
40,HS-grad,Male,Own-child,Never-married,<=50K
24,Some-college,Female,Own-child,Married-civ-spouse,<=50K
40,HS-grad,Female,Not-in-family,Never-married,<=50K
38,5th-6th,Male,Husband,Married-civ-spouse,<=50K
60,9th,Female,Not-in-family,Widowed,<=50K
```

Выходные данные

Результатом работы методы являются синтетические данные с обеспечением дифференциальной приватности в формате CSV-файла с заданным количеством записей.

3.6 Тестирование программного обеспечения

Методика тестирования

Тестирование реализованного программного обеспечения проводилось в комплексном формате и включало в себя типы тестов: модульное тестирование — метод тестирования, при котором проверяется корректности работы отдельных компонентов программы в изоляции от остальных частей системы; функциональное тестирование — метод тестирования, при котором проверяется корректноая работа системы в целом.

Результаты тестирования

Результаты тестирования показали корректность работы разработанного метода для различных входных данных. Были протестированы следующие аспекты:

— Загрузка датасета из файла;

— Анализизирование датасета;

— Создание структуры Байесовской сети;

— Добавление шума;

— Генерация синтетических данных;

— Сохранение выходных данных.

Все тесты были пройдены успешно.

3.7 Пример пользовательского интерфейса

Интерфейс пользователя приложения представлен на рисунке 3.2. В интерфейсе присутствуют поля для ввода данных, также многие поля изначальная заполнены данными по умлчанию.

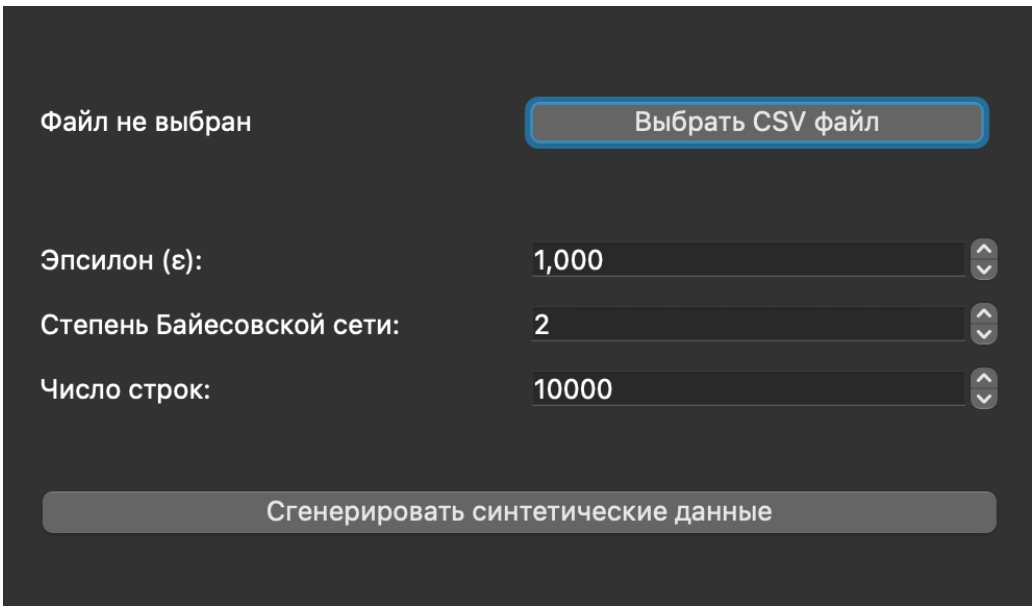


Рисунок 3.2 – Реализация пользовательского интерфейса

4 Исследовательская часть

4.1 Технические характеристики

Технические характеристики компьютера, на котором проводилось исследование:

— процессор Intel Core i5-12900K;

— 16 Гбайт оперативной памяти;

— операционная система Ubuntu 22.04.

На протежянии всего периода исследования компьютер был подключен к сети питания и количество фоновых процессов было сведено к минимуму.

4.2 Методика исследования

Для оценки эффективности разработанного метода обеспечение дифференциальной приватности при генерации синтетических данных. Исследование включало в себя измерение следующих характеристик:

— время работы метода при различных размерах данных (количества записей и количества атрибутов);

— качество генерируемых синтетических данных;

Также исследование включало сравнение с альтернативными методами генерации без дифференциальной приватности.

При проведении исследования:

— количество записей в исходных данных было равно 10000, за исключением тех замеров, в которых оно изменялось для исследования зависимостей;

— количество атрибутов в исходных данных было равно 9, за исключением тех замеров, в которых оно изменялось для исследования зависимостей;

— параметр приватности был равен 1, за исключением тех замеров, в которых он изменялся для исследования зависимостей;

— степень Байесовской сети был равен 2, за исключением тех замеров, в которых она изменялась для исследования зависимостей;

— число генерируемых записей было равно 100000, за исключением тех замеров, в которых оно изменялось для исследования зависимостей;

4.3 Исследование характеристик

4.3.1 Время работы

Одной из ключевых характеристик реализованного метода является зависимость время работы от разных входных параметров.

Для исследования данной зависимости были проведены измерения времени работы для:

1. исходных датасетов разного размера количества записей;
2. исходных датасетов разного размера количества атрибутов;
3. разных параметрах приватности;
4. разных степенях БС.

На рисунке 4.1 представлена диаграмма зависимости времени работы от размера количества записей входного датасета:

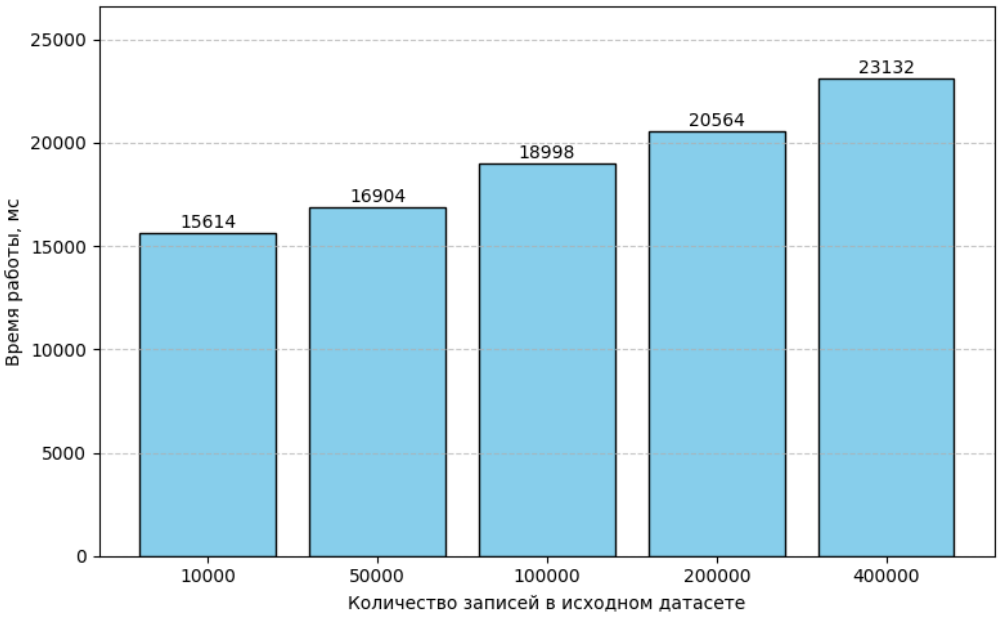


Рисунок 4.1 – Зависимость времени работы от размера количества записей входного датасета

На рисунке 4.2 представлена диаграмма зависимости времени работы программы от размера количества атрибутов входного датасета:

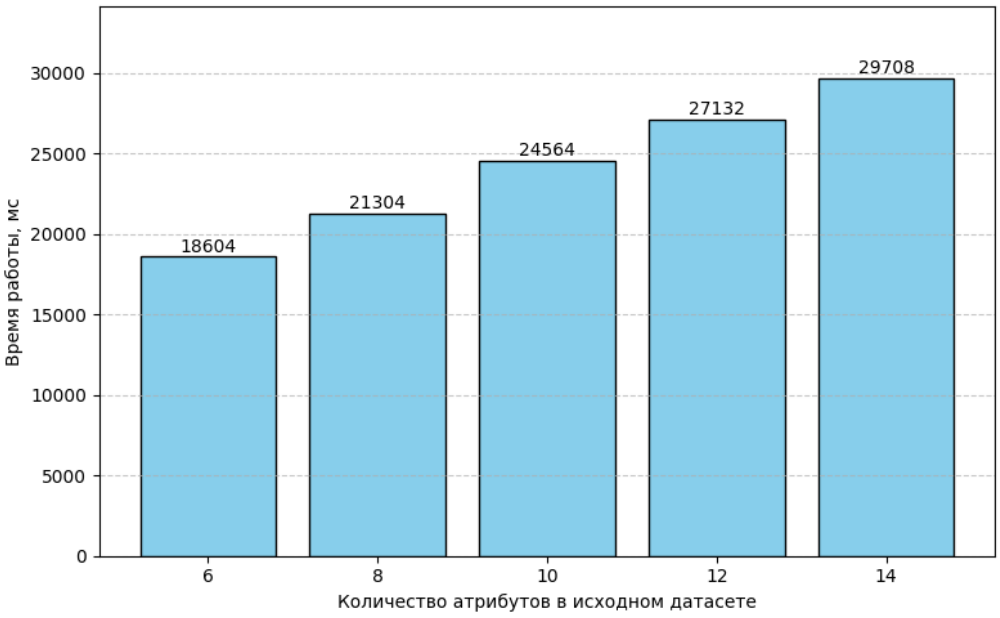


Рисунок 4.2 – Зависимость времени работы программы от размера количества атрибутов входного датасета

Результаты измерений показывают, что: время работы увеличивается вместе с количеством атрибутов в датасета. Также из двух диаграмм видно, что при увеличении количества атрибутов на выполнение работы уходит больше времени, чем при увеличении количества записей.

На рисунке 4.3 представлена диаграмма зависимости времени работы от разных параметров приватности при одинаковых других входных параметрах:

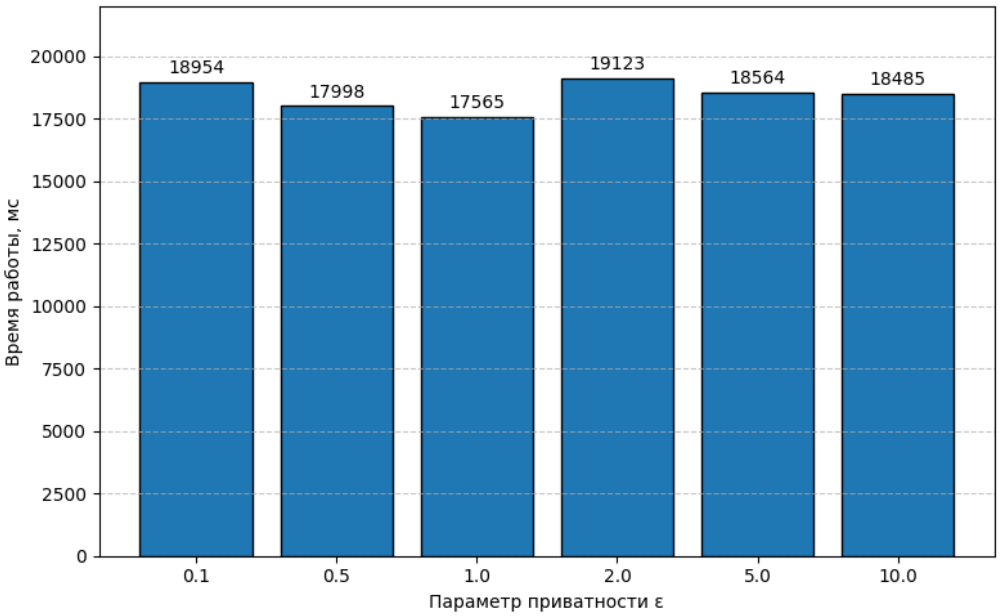


Рисунок 4.3 – Зависимость времени работы от разных значений параметра приватности

На рисунке 4.4 представлена диаграмма зависимости времени работы от степени Байесовской сети:

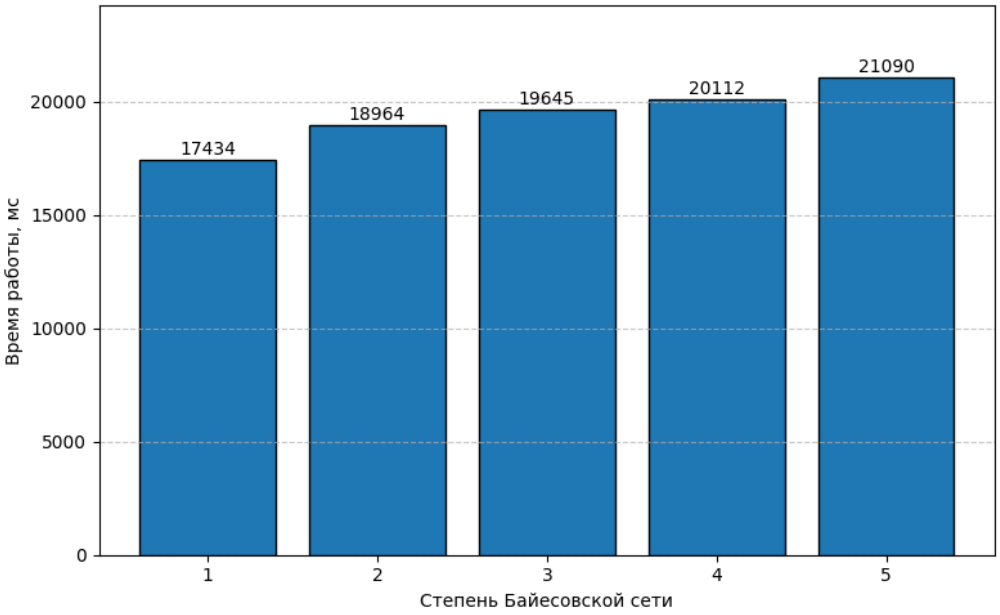


Рисунок 4.4 – Зависимость времени работы от степени Байесовской сети

4.3.2 Качество данных

Исследуется зависимость качества генерируемых синтетических данных от значения параметра приватности ε. Результаты измерений представлены в таблице 4.1 и на рисунке 4.5.

Таблица 4.1 – Влияние параметра ε на качество синтетических данных

Параметр ε	Фробениусова норма
0.1	0.31
0.5	0.22
1.0	0.16
2.0	0.12
5.0	0.07
10.0	0.03

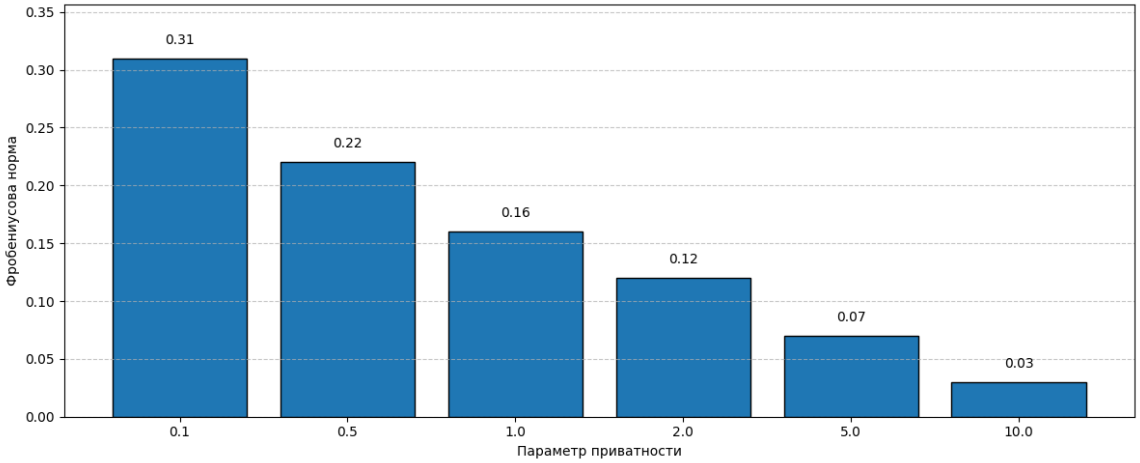


Рисунок 4.5 – Влияние параметра ε на качество синтетических данных

Оптимальное значение $\varepsilon = 1.0{-}2.0$ обеспечивает баланс между приватностью и полезностью данных.

4.4 Сравнение с альтернативными методами

Проводится сравнение разработанного метода с альтернативами:

1. ctGAN без дифференциальной приватности;
2. Предложенный метод с $\varepsilon = 1.0$.
3. VAE без дифференциальной приватности;

Результаты сравнения представлены в таблице 4.2 и на рисунке 4.6 и 4.7:

Таблица 4.2 – Сравнение с альтернативными методами

Метод	Фробениусова норма	Время генерации, мс
Исходные данные	0.00	—
ctGAN без ДП	0.08	45211
Предложенный метод	0.12	542437
VAE без ДП	0.09	50109

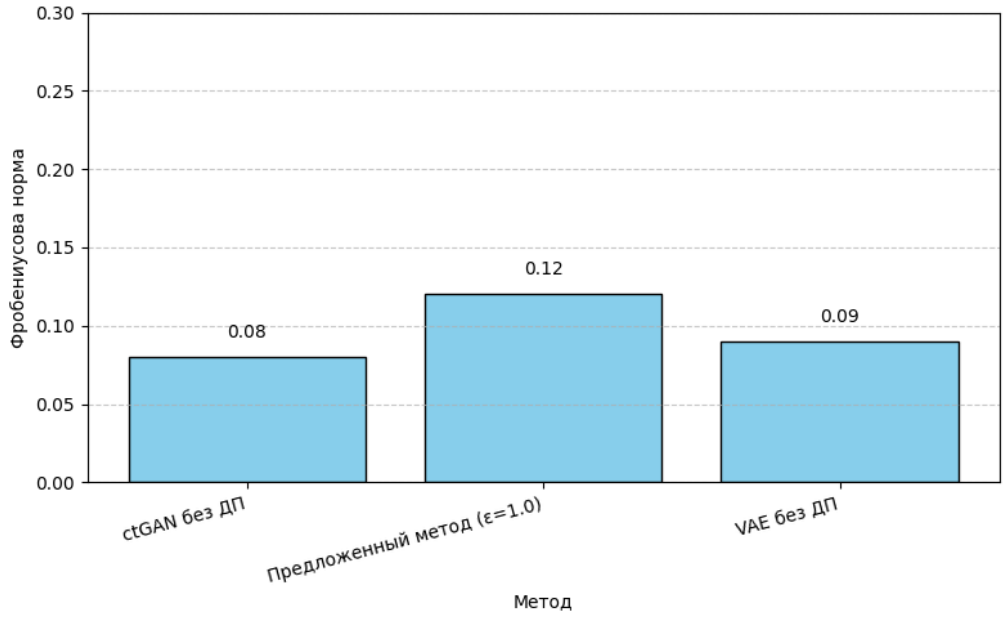


Рисунок 4.6 – Сравнение разработанного метода с альтернативами

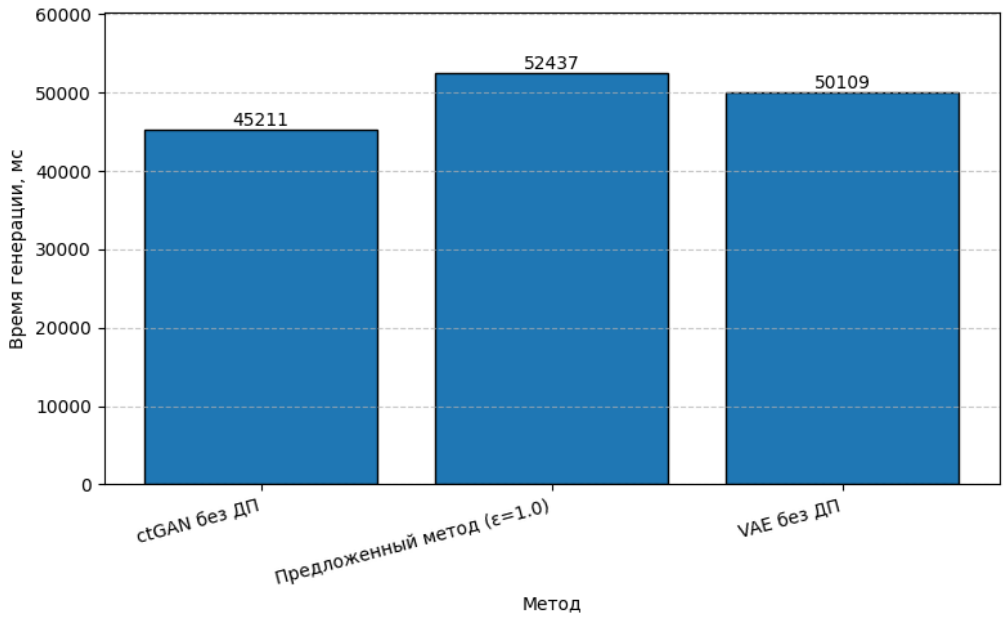


Рисунок 4.7 – Сравнение разработанного метода с альтернативами

4.5 Выводы

В данном разделе были проведены исследования характеристик разработанного метода обеспечения дифференциальной приватности при генерации синтетических данных. Основные результаты исследования:

— Результаты измерений показывают, что: время работы увеличивается вместе с количеством записей в датасет

— Результаты измерений показывают, что: время работы увеличивается вместе с количеством атрибутов в датасета

— Оптимальное значение $\varepsilon = 1.0{-}2.0$ обеспечивает баланс между приватностью и полезностью данных;

— Разработанный метод показывает высокое качество данных при обеспечении дифференциальной приватности. Точность составляет 0.12, что является приемлемым компромиссом.

ЗАКЛЮЧЕНИЕ

В результате выполнения данной дипломной работы была достигнута цель, а именно разработан метод обеспечения дифференциальной приватности при генерации синтетических данных.

Для достижения поставленной цели были решены следующие задачи:

— проанализировать и классифицировать существующие методы генерации синтетических данных и дифференциальной приватности;

— сформулировать концепцию комбинированного метода на уровне идеи, формализовать задачу в виде функциональной модели;

— выделить ключевые этапы разрабатываемого метода и описать их в виде детализированной диаграммы IDEF0 и схем алгоритмов;

— разработать программное обеспечение, реализующее разработанный метод;

— исследовать характеристики разработанного метода при различных входных данных;

— провести сравнение результатов работы реализованного метода с альтернативными методами.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Voigt P., Bussche A.* The eu general data protection regulation (gdpr) // Cham: Springer International Publishing. — 2017. — С. 10—15.
2. *Борисенко О. В.* Анализ федерального закона№ 152-ФЗ «о персональных данных». — 2012. — С. 26—30.
3. *Куляшова З. В. и Мурзич О. А.* Синтетические данные и их применение // ФГАОУ ВО Санкт-Петербургский политехнический университет Петра Великого. — 2022. — С. 225—227.
4. *Ильяшенко О. Ю. и Шувалова А. В.* Синтетические данные как способ совершенствования алгоритмов машинного обучения // ФГАОУ ВО Санкт-Петербургский политехнический университет Петра Великого. — 2022. — С. 30—34.
5. *Рабчевский А. Н.* Синтетические данные и развитие нейросетевых технологий. Учебник для вузов // Москва, Издательство Юрайт. — 2025. — С. 187.
6. *Федоренко С. А. и Фешина Е. В.* Сферы применения генеративно-состязательных нейросетей // ФГБОУ ВО Кубанский государственный аграрный университет имени И.Т. Трубилина. — 2019. — С. 226—228.
7. *Айрапетов А. Э. и Коваленко А. А.* Исследование генеративно-состязательной сети // МГТУ им. Н.Э. Баумана. — 2022.
8. *Тополян С. Г.* Развитие генеративных моделей логических системах принятия решений // Вестник науки. — 2025.
9. *Житков Н. М.* Генеративно-состязательные сети как решение проблемы малого объема экспериментальных данных // Москва, Издательский дом "Научная библиотека". — 2022. — С. 75—76.
10. *Kim J., Seok J.* ctGAN: combined transformation of gene expression and survival data with generative adversarial network // Briefings in Bioinformatics. — 2024.
11. *Качнов С. А.* Генерация данных с помощью вариационного автокодировщика // Интеллектуальные системы. Теория и приложения. — 2021. — С. 228—232.

12. *Звягин Л.* Метод байесовских сетей и ключевые аспекты байесовского моделирования // ФГАОУ ВО Санкт-Петербургский государственный электротехнический университет ЛЭТИ им. ВИ Ульянова. — 2019. — С. 30—34.

13. *Крыжановская А. В. и Газизов А. Р.* Модель защиты информационной системы на основе псевдонимизации данных // Вестник науки. — 2024.

14. *Wood A., Altman M.* Differential Privacy: A Primer for a Non-Technical Audience // ChemRN: Computational Materials Science (Topic). — 2018.

15. *Hu X., Yuan M.* Differential privacy in telco big data platform // VLDB Endowment. — 2015. — С. 1692—1703.

16. *Криштопова Е. А.* Защита удаленной пользовательской статистики с помощью механизмов дифференциальной приватности // Технические средства защиты информации : тезисы докладов XVII Белорусско-российской научно – технической конференции. — 2019.

17. pandas [Электронный ресурс]. — URL: `https://pandas.pydata.org`. — (Дата обращения: 05.04.2025).

18. pytorch [Электронный ресурс]. — URL: `https://pytorch.org`. — (Дата обращения: 05.04.2025).

19. catboost [Электронный ресурс]. — URL: `https://catboost.ai`. — (Дата обращения: 05.04.2025).

20. catboost [Электронный ресурс]. — URL: `https://scikit-learn.org/`. — (Дата обращения: 05.04.2025).

21. Visual Studio Code [Электронный ресурс]. — URL: `https://code.visualstudio.com`. — (Дата обращения: 05.04.2025).

ПРИЛОЖЕНИЕ А

Презентация к выпускной квалификационной работе содержит 19 слайдов.