Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ

НА ТЕМУ:

Метод обеспечения дифференциальной приватности при генерации при генерации синтетических данных

Студент ИУ7-84Б _____ Н. А. Турчанский
(группа) (подпись) (инициалы, фамилия)

Руководитель ВКР _____ А. Л. Исаев
(подпись) (инициалы, фамилия)

Нормоконтролер _____
(подпись) (инициалы, фамилия)

2025 год

ВВЕДЕНИЕ

В эпоху цифровой трансформации данные стали ключевым ресурсом для анализа, машинного обучения и принятия решений. Однако использование реальных данных, особенно в чувствительных областях (медицина, финансы, персональная аналитика), сталкивается с проблемами конфиденциальности и законодательных ограничений, таких как GDPR и ФЗ-152 «О персональных данных».

Цель выпускной квалификационной работы — разработка метода обеспечения дифференциальной приватности при генерации синтетических данных.

Для достижения поставленной цели необходимо решить следующие задачи:

— проанализировать и классифицировать существующие методы генерации синтетических данных и дифференциальной приватности;

— сформулировать концепцию комбинированного метода на уровне идеи, формализовать задачу в виде функциональной модели;

— выделить ключевые этапы разрабатываемого метода и описать их в виде детализированной диаграммы IDEF0 и схем алгоритмов;

— разработать программное обеспечение, реализующее разработанный метод;

— исследовать характеристики разработанного метода при различных входных данных;

— провести сравнение результатов работы реализованного метода с альтернативными методами.

1 Аналитическая часть

1.1 Синтетические даннные

Синтетические данные — это сгенерированные компьютером данные, обладающие теми же характеристиками и статистическими свойствами, что и реальные данные. Они применяются в том случае, если получение реальных данных затруднено, требует больших затрат, ставит под угрозу конфиденциальность пользователей или занимает слишком много времени. Синтетические данные могут быть текстовыми или табличными, а также представлять собой видео, изображения или звуки, как и реальные данные.

Синтетические данные разделяют на три категории:

1. Полностью синтетические данные, которые не имеют с реальными данными почти ничего общего и генерируются на основе некоторых признаков реальных данных. Они сохраняют статистические свойства реальных данных и фактически заменяют их.

2. Частично синтетические данные, которые заменяют только некоторые значения в реальных данных, если они являются конфиденциальными или содержат пропуски.

3. Гибридные синтетические данные, которые генерируются с использованием и реальных, и полностью синтетических данных: для реальных данных выбираются близкие им синтетические, и они объединяются, формируя гибридные данные.

Категориальные признаки

Важную роль при генерации синтетических данных играют категориальные признаки, которые ялвяются переменными, принимающими ограниченное число значений (например, "пол "страна "тип товара"). Категориальные признаки позволяют выразить свойства и разбить данные на группы.

Категориальные признаки разделяют на три типа:

— Номинативные — нет порядка (например, "цвет": красный, синий, зелёный);

— Порядковые — есть иерархия (например, "уровень образования": школа, бакалавр, магистр);

— Бинарные — два значения (например, "да/нет").

От типа зависит выбор метода кодирования. Методы кодирования разбивают на:

— Label Encoding (Метка чисел) — каждой уникальной категории присваивается целое число от 0 до $N-1$, где N - количество категорий;

— One-Hot Encoding (OHE) — Создаёт N бинарных столбцов для N уникальных категорий. Каждая категория представляется вектором с одной "1"и остальными "0";

— Target Encoding (Mean Encoding) — замена категории средним значением целевой переменной для этой категории;

— Frequency Encoding — замена категорий их частотой в датасете;

— Embedding (Векторные представления) — преобразование категорий в плотные векторы фиксированной размерности через обучение.

Корреляция

Корреляция в контексте генерации синтетических данных — это статистическая взаимосвязь между признаками, которую необходимо сохранить, чтобы искусственные данные оставались реалистичными и пригодными для анализа или машинного обучения. Если синтетические данные игнорируют связи, то неизбежны нереалистичные комбинации, снижение точности моделей, ошибки в анализах.

Проверить корреляцию можно несколькими способами:

— визуализация;

— статистические тесты;

— метрики.

1.2 Методы генерации синтетических данных

Создание синтетических данных включает в себя различные методы и подходы, которые позволяют генерировать данные, максимально приближенные к реальным по своим характеристикам и структуре.

1.2.1 Генеративно – состязательные сети

Генеративные состязательные нейросети — это класс алгоритмов искусственного интеллекта, используемых в машинном обучении без вмешательства человека, реализованных системой двух нейронных сетей, конкурирующих друг с другом в игровой среде с нулевой суммой.

1.2.2 GAN

В системе GAN одна генеративная сеть G генерирует синтетические образцы, а другая сеть — дискриминативная D, старается отличить правильные («оригинальные») образцы от неправильных (синтетических).

Используя шум на входе, генеративная сеть G создает новый образец, смешав несколько исходных образцов. Цель генератора можно описать выражением 1.1

$$\min_G \log\{1 - D[G(z)]\} \tag{1.1}$$

где D — функция дискриминатора; G — функция генератора; z — входные параметры.

Дискриминативная сеть D обучается различать подлинные и поддельные образцы, а результаты различения подаются на вход генеративной сети так, чтобы она смогла подобрать лучший набор параметров и дискриминативная сеть уже не смогла бы отличить подлинные образцы от поддельных

При этом сеть D, анализируя образцы из оригинальных и синтетических данных, достигает некоторой точности различения. Постепенно синтетические образцы на выходе генеративной сети становятся все более качественными. Цель дискриминатора D можно описать выражением 1.2

$$\max_D\{\log D(x_t) + \log(1 - D[x_f])\} \tag{1.2}$$

где x_t — исходные данные; $x_f - G(z)$ — сгенерированный образец.

Таким образом, алгоритм представляет собой минимаксную состязание для двух нейронных сетей, которое можно описать выражением 1.3

$$\min_G \max_D \{\log D(x_t) + \log(1 - D[G(z)])\} \tag{1.3}$$

Структура сети GAN представлена на рисунке 1.1



Рисунок 1.1 – Структура сети GAN

Для синтезации данных необходимо данные от генератора не только подавать на дискриминатор, но и складывать их в отдельную базу, особенно в фазе обучения, близкой к достижению минимаксного состояния равновесия. В этом случае получится множество данных, очень близких к оригинальным, которые и являются искомыми синтетическими данными.

Структурная схема GAN, модифицированная для генерации синтетических данных, представлена на рисунке 1.2.

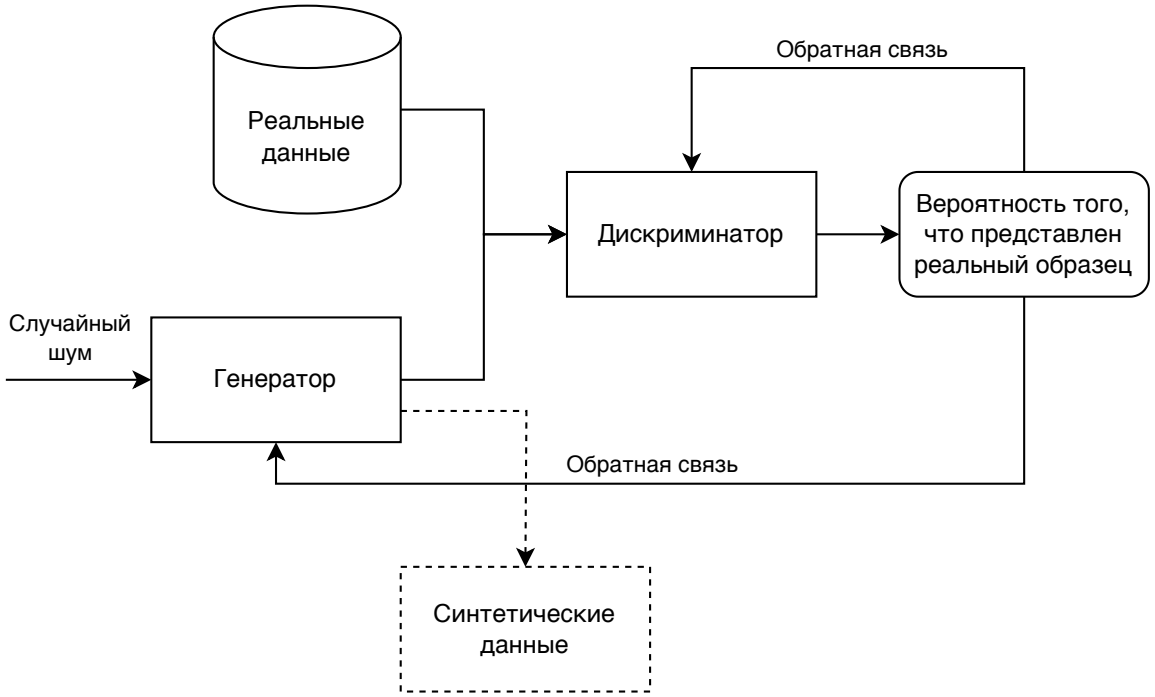


Рисунок 1.2 – Структурная схема GAN, модифицированная для генерации синтетических данных

1.2.3 cGAN

Основное отличие cGAN от классической GAN заключается в том, что на дискриминатор и генератор в качестве дополнительного входного слоя подается дополнительный параметр , который может являться условием при генерации.

На вход генератора подаются случайный шум и информация, которые объединяются в совместное входные параметры, в результате чего состязательная система обучения позволяет проявлять большую гибкость.

Структурная схема cGAN представлена на рисунке 1.3.

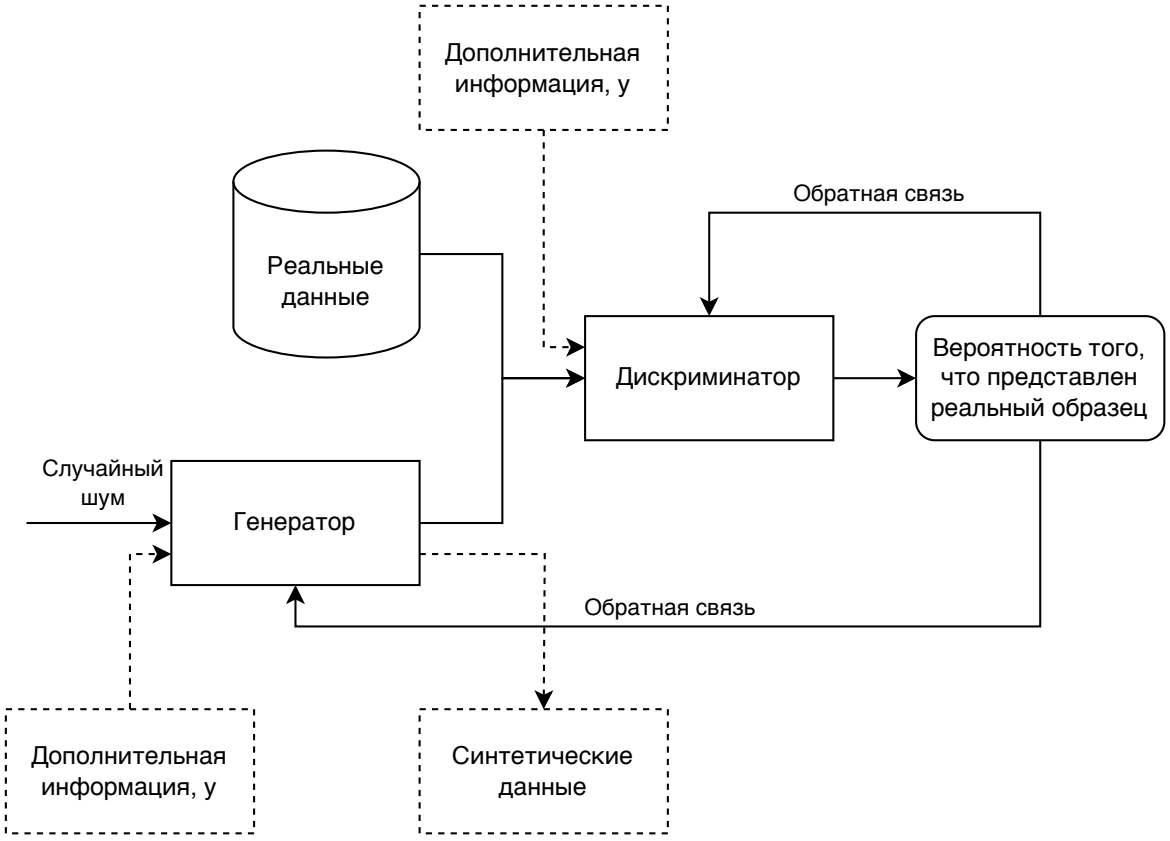


Рисунок 1.3 – Структурная схема cGAN

1.2.4 ctGAN

В традиционных GAN генератор повторяет распределение реальных данных. В случае дисбаланса в категориальных колонках, если при обучении данные выбираются случайным образом, то строки не будут представлены в достаточной степени и, следовательно, генератор может быть обучен непра-

вильно. Для решения этих проблем была предложена архитектура cGAN, адаптированная для генерации равномерно распределенных многомодальных табличных данных, на- званная ctGAN (conditional mabular GAN).

Задача генератора CTGAN состоит в том, чтобы все категории из дискретных атрибутов были равномерно отобраны в процессе обучения, а во время тестирования было восстановлено реальное распределение данных.

В основу идей CTGAN положено следующее соображение: пусть $k*$ — значение из $i*-$ дискретного столбца D_{i*}, которому должны соответствовать сгенерированные выборки r. Тогда генератор можно интерпретировать как условное распределение строк с учетом конкретного значения в данном столбце.

1.2.5 Статические и вероятностные методы

Статистические и вероятностные методы представляют собой фундаментальный подход к генерации синтетических данных, основанный на математическом моделировании распределений реальных данных.

1.2.6 Байесовские сети

Байесовские сети — это тип вероятностной графической модели, которая представляет отношения между переменными с использованием ориентированного ациклического графа, где:

1. узлы соответствуют случайным переменным;
2. дуги отражают причинно-следственные связи;
3. каждому узлу сопоставлено условное распределение вероятностей.

1.2.7 Сравнение методов

— 1 — табличные данные. Возможность метода генерировать табличные данные;

— 2 — сложность обучения. Формализуем сложность обучения в виде функции $T_{train} = f(N, d, L, k)$, где N — объем обучающих данных; d — размерность данных; L — количество слоев/параметров; k — число итераций обучения;

— 3 — уровень дифференциальной приватности. Наличие у метода функционала дифференциальной приватности.

	1	2	3
GAN	Нет	$O(k \cdot N \cdot d^2 \cdot L)$	Нет
cGAN	Нет	$O(k \cdot N \cdot (d + c)^2 \cdot L)$	Нет
ctGAN	Да	$O(k \cdot N \cdot d \cdot L)$	Нет
БС	Да	$O(2^N)$	Нет

1.3 Дифференциальная приватность

Дифференциальная конфиденциальность — это математическая концепция, которая обеспечивает информационно-теоретическую гарантию конфиденциальности. Стандартным способом реализации дифференциальной конфиденциальности является введение достаточного количества шума в данные. Однако в дополнение к другим ограничениям дифференциальной конфиденциальности этот процесс добавления шума влияет на точность и полезность данных, но минимизирует влияние индивидуальных записей на результаты статистических запросов.

Дифференциальная приватность обеспечивает защиту личной информации, гарантируя, что результаты анализа не позволят точно определить информацию о конкретных индивидах. В рамках ДП данные обрабатываются с добавлением шума, что минимизирует влияние индивидуальных записей на результаты статистических запросов. Таким образом, как показано на рисунке 1.4, даже если в набор данных добавляется или исключается информация о конкретном индивиде, это не влияет на общие выводы о группе

Представим БД, содержащую медицинские записи 100 человек, из которых 20 страдают диабетом. Злоумышленник хочет узнать, есть ли у человека X диабет, и уже узнал, что 19 из остальных 99 человек в выборке являются диабетиками. Запрашивая базу данных и получая информацию о том, что в выборке 20 диабетиков, злоумышленник делает вывод, что человек X также страдает диабетом. Этот процесс извлечения дедуктивной информации называется дифференцированной атакой

Теперь представим, что доступ к данным, хранящихся в БД, предоставляется через систему запросов с дифференциальной приватностью. Когда злоумышленник делает запрос, система возвращает истинное значение с некоторым случайным шумом. Даже если злоумышленник знает все о других 99 людях, то он не может быть уверен, есть ли у человека X диабет. Конфиденциальность человека X защищена, поскольку его риск нарушения конфиденциальности остается примерно одинаковым независимо от того, входит ли он в набор данных или нет. Это справедливо для любого отдельного человека и любого набора данных, независимо от того, насколько необычными или отличительными могут быть данные конкретного индивидуума.

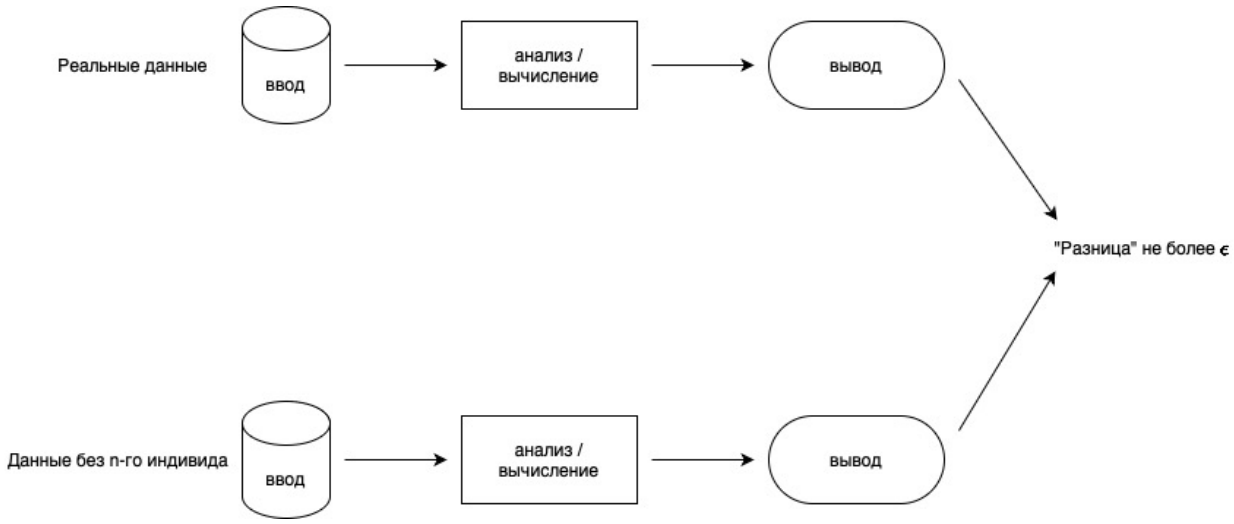


Рисунок 1.4 – Принцип ДП

1.4 Типы приватности

Параметр приватности ϵ — это неотрицательное значение, определяющее уровень приватности, который влияет на количество добавляемого шума

1.4.1 ϵ – дифференцированная приватность

Модель ϵ – дифференцированной приватности гарантирует, что результаты анализа данных не изменятся, если одна запись будет добавлена или удалена.

Механизм M обеспечивает ϵ – дифференциальную приватность, если для любых двух соседних наборов данных D и D' (различающихся на одну запись) выполняется условие по формуле

$$Pr[M(D)] \leqslant \exp(\epsilon) \times Pr[M(D')] \tag{1.4}$$

, где ϵ — параметр приватности

1.4.2 (ϵ, δ) – дифференцированная приватность

Модель (ϵ, δ) – дифференцированной приватности вводит дополнительный параметр δ, который ослабляет строгие гарантии приватности. Параметр δ определяет вероятность того, что гарантия приватности будет нарушена в некоторых случаях. Это дает гибкость в балансе между приватностью и точностью результатов.

Механизм M обеспечивает (ϵ, δ) – дифференциальную приватность, если для любых двух соседних наборов данных D и D' (различающихся на одну запись) выполняется условие по формуле

$$Pr[M(D)] \leqslant \exp(\epsilon) \times Pr[M(D')] + \delta \tag{1.5}$$

, где ϵ — параметр приватности, δ — параметр вероятности нарушения приватности

1.5 Типы механизмов

Параметр чувствительности — это максимальное изменение результата механизма при изменении одного элемента в базе данных.

Чувствительностью механизма M является максимум разности значений механизма для любых двух соседних наборов данных D и D' (различающихся на одну запись) и вычисляется по формуле

$$\Delta M = \max(|M(D) - M(D')|) \tag{1.6}$$

, где M — параметр чувствительности.

1.5.1 Механизм Лапласа

Лапласов механизм добавляет к результату запроса шум, сгенерированный из распределения ЛапласаРезультат Лапласова механизма вычисляется по формуле

$$M'(D) = M(D) + \mathrm{Lap}(0, \frac{\Delta M}{\epsilon}) \tag{1.7}$$

где ΔM — параметр чувствительности, ϵ — параметр приватности

1.5.2 Механизм Гаусса

Гауссов механизм похож на Лапласов, но шум добавляется на основе нормального (Гауссова) распределения. К результатам запроса добавляется шум по формуле

$$M'(D) = M(D) + \mathcal{N}(0, \sigma^2) \tag{1.8}$$

, где $\mathcal{N}(0, \sigma^2)$ — нормальное распределение.

Параметр σ вычисляется по формуле

$$\sigma = \frac{\Delta M \sqrt{2 \ln(1.25/\delta)}}{\epsilon} \tag{1.9}$$

1.5.3 Экспоненциальный механизм

Экспоненциальный механизм работает путем добавления случайности в процесс выбора элементов, где вероятность выбора каждого элемента зависит от его "качества"(оценки полезности) и параметра приватности.

Для двух соседних наборов данных D и D' экспоненциальный механизм M обеспечивает экспоненциальную приватность, если вероятность выбора результата r зависит от его полезности $u(r, D)$, и вычисляется по формуле 1.10

$$P[M(D)] \propto \exp(\epsilon u(r, D)) \tag{1.10}$$

, где ϵ — параметр приватности, $u(r, D)$ — оценка полезности

1.5.4 Сравнение методов

— 1 — тип шума. Тип шума, который реализует данный механизм;

— 2 — тип приватности. Тип приватности, который использует данный метод;

	1	2
Лапласовский	Лаплас	$(\epsilon, 0)$
Гауссовский	Гаусс	(ϵ, δ)
Экспоненциальный	Дискретный	ϵ

1.6 Формализация задачи

В ходе выполнения выпускной квалификационной работы необходимо разработать и реализовать метод, предоставляющий возможность генерировать синтетические данные с гарантиями дифференциальной приватности. Концепция метода заключается в совместном использовании метода генерации синтетических данных и метода дифференциальной приватности путем добавления шума на этапе генерации.

Также метод должен иметь функционал выбора количества генерируемых записей.

Метод должен быть реализоан как приложение с пользовательским интерфейсом.

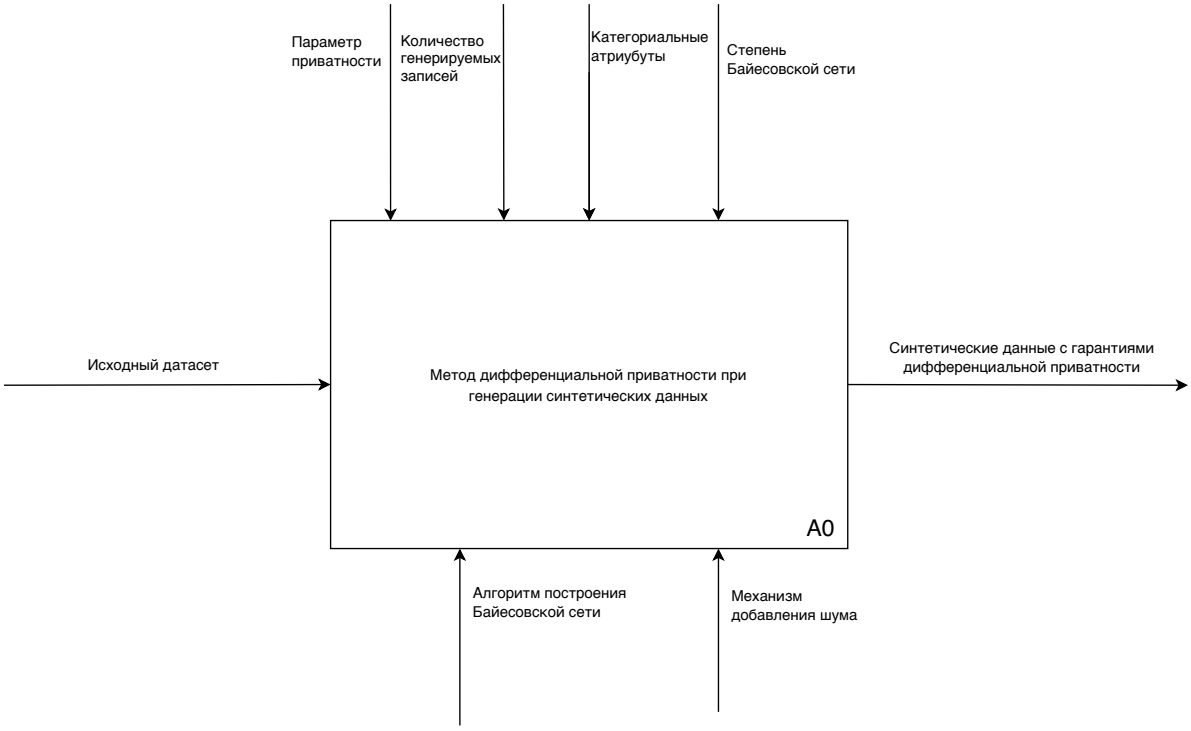


Рисунок 1.5 – idef0

1.7 Формат табличных данных

1.7.1 CSV

CSV (Comma-Separated Values) — текстовый формат, предназначенный для представления табличных данных. Строка таблицы соответствует строке текста, которая содержит одно или несколько полей, разделенных запятыми.

В первой строке допускается указать наименования столбцов данных, но это не является обязательным требованием. Данный формат не предполагает типизацию данных, все значения данных считаются строками. CSV является наиболее часто используемым форматом для хранения структурированных данных.

1.7.2 Parquet

Parquet — это открытый, колонно-ориентированный формат хранения данных, который используется для эффективной обработки больших объёмов данных в распределённых системах. Он был создан как часть экосистемы Hadoop и поддерживает аналитику и обработку данных в таких распределённых системах как Apache Hadoop, Apache Spark, Apache Drill и других.

1.7.3 Avro

Формат Avro - это компактный, быстрый и сериализуемый формат данных, разработанный Apache Software Foundation . Он обеспечивает схему данных в JSON формате, что делает его самоописывающим. Avro поддерживает различные типы данных, сжатие данных и является эффективным для передачи данных между различными системами. Он широко используется в Big Data и распределенных системах для обмена данными и хранения данных.

2 Конструкторская часть

2.1 Архитектура метода

Разрабатываемый метод обеспечения дифференциальной приватности при генерации синтетических основан на Байесовских сетях и состоит из двух основных этапов:

— построение структуры Байесовской сети с дифференциальной приватностью;

— генерация синтетических данных.

На рисунке 2.1 представлена функциональная модель разрабытыаемого метода.

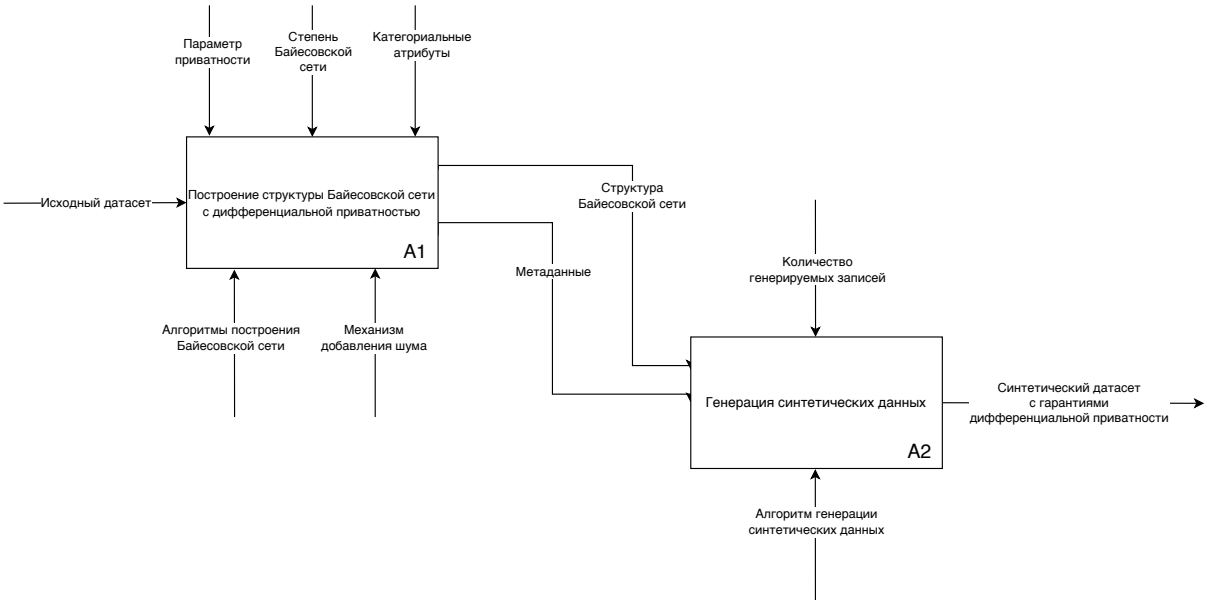


Рисунок 2.1 – Функциональная модель разрабытыаемого метода

2.2 Предварительная обработка данных

Тип данных является важным компонентом домена атрибутов. Метод поддерживает четыре типа данных и позволяет пользователям явно указывать их. Если тип данных атрибута не указан пользователем, то метод делает это автоматически.

Тип данных атрибута ограничивает его домен, который может быть дополнительно ограничен, если атрибут категоричен. Например, в наборе

данных студентов атрибут может принимать только значения BS, BA, MS или PhD. Домен атрибута — $\{BS, BA, MS, PhD\}$. Атрибут считается категориальным, если во входном наборе данных наблюдается ограниченное количество различных значений для этого атрибута.

Этап предварительной обработки данных продемонстрирован на рисунке 2.2

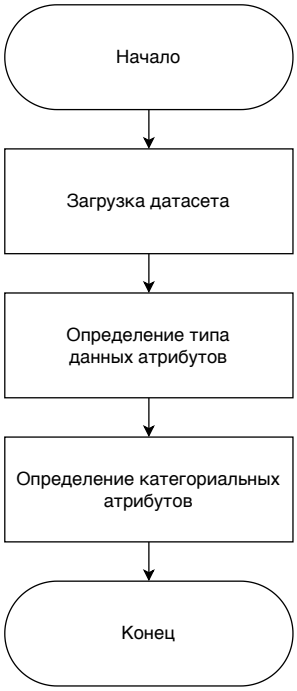


Рисунок 2.2 – Этап предварительной обработки данных

2.3 Построение структуры БС с ДП

На листинге представлен алгоритм, который строит БС $\mathcal{N}$ из входного набора данных D, атрибутов A и максимального количества родителей узла БС k. В этом алгоритме V — это набор посещаемых атрибутов, а Π - это подмножество V, которое станет родителями узла X, если будет добавлено к $\mathcal{N}$. Атрибуты Π определяются путем поиска максимального $I(X, \Pi)$, который вычисляется по формуле 2.1:

$$I(X_i; \Pi) = \sum_{x_i, \pi} P(x_i, \pi) \log \frac{P(x_i, \pi)}{P(x_i)P(\pi)} + Lap(\frac{1}{n\epsilon}) \tag{2.1}$$

, где ϵ — параметр приватности, n — количество записей входных данных.

Algorithm 1: Preprocess

Input : D : датасет;
A : набор атрибутов;
k : максимальное количество родительских узлов;
Output : N : структура Байесовской сети.

begin
- $\mathcal{N} \leftarrow \emptyset$ и $V \leftarrow \emptyset$
- $X_1 \leftarrow {}_R A$
- $A \cup \{(X_1, \emptyset)\}$ и $\mathcal{N} \cup X_1$
- **for** $i \leftarrow 2$ *to* $|A|$ **do**
  - $\Omega \leftarrow \emptyset$
  - $p \leftarrow \min(k, |V|)$
  - **for** *each* $X \in A$ *and each* $\Pi \in \binom{V}{p}$ **do**
    - $\Omega \cup \{(X, \Pi)\}$
  - $(X_i, \Pi_i) = \underset{(X,\Pi)\in\Omega}{\operatorname{argmax}} I(X; \Pi)$
  - $\mathcal{N} \cup (X_i, \Pi)$
- **return** $\mathcal{N}$

2.3.1 Генерация синтетических данных

На начальном этапе генерации метод читает построенную БС. Корневые атрибуты, которые не зависят от других переменных, сэмплируются из их безусловных распределений, а дочерние — из условных. Обход сети происходит в топологическом порядке.

Algorithm 2: Preprocess

Input :
n : количество записей для генерации;
S : метаданные датасета;
s : начальное число.

Output :
$keys$: отсортированный массив нормализованных ключей;
$data$: отсортированный по массиву ключей массив указателей;
cdf : массив значений функции распределения.

begin
установить начальное значение = s для псевдо-случайной генерации чисел
Пример корневого атрибута из безусловного распределения сформировать оставшиеся атрибуты из условного распределения
return Сформированный датасет

3 Технологическая часть

3.1 Выбор средств программной реализации

Выбор языка программирования

В качестве языка программирования был выбран Python так как:

— поддерживает библиотеки для анализа данных (pandas);

— обладает инструментами для реализации машинного обучения (pytorch, catboost, scikit-learn);

— обладает большим сообществом разработчиков и является одним из наиболее часто используемых языков.

Среда разработки

Для разработки программного обеспечения была выбрана интегрированная среда разработки (IDE) Visual Studio Code (VS Code), который обладает следующими преимуществами:

1. Производительность и низкое потребление ресурсов. VS Code отличается высокой скоростью работы и умеренным использованием системных ресурсов;

2. Экосистема расширений. Магазин расширений (Extensions Marketplace) предоставляет доступ к множеству плагинов для кастомизации среды под конкретные нужды;

3. Активное сообщество и регулярные обновления. VS Code разрабатывается Microsoft при поддержке open-source-сообщества, благодаря чему выходят частые обновления с новыми функциями и исправлениями багов.

3.2 Реализация программного обеспечения

Реализованное программное обеспечение реализует метод дифференциальной приватности при генерации синтетических данных. Написанная

программа включает в себя компоненты, которые организованы в модули с разделением ответственности.

На рисунке 3.1 представлена диаграмма модулей.

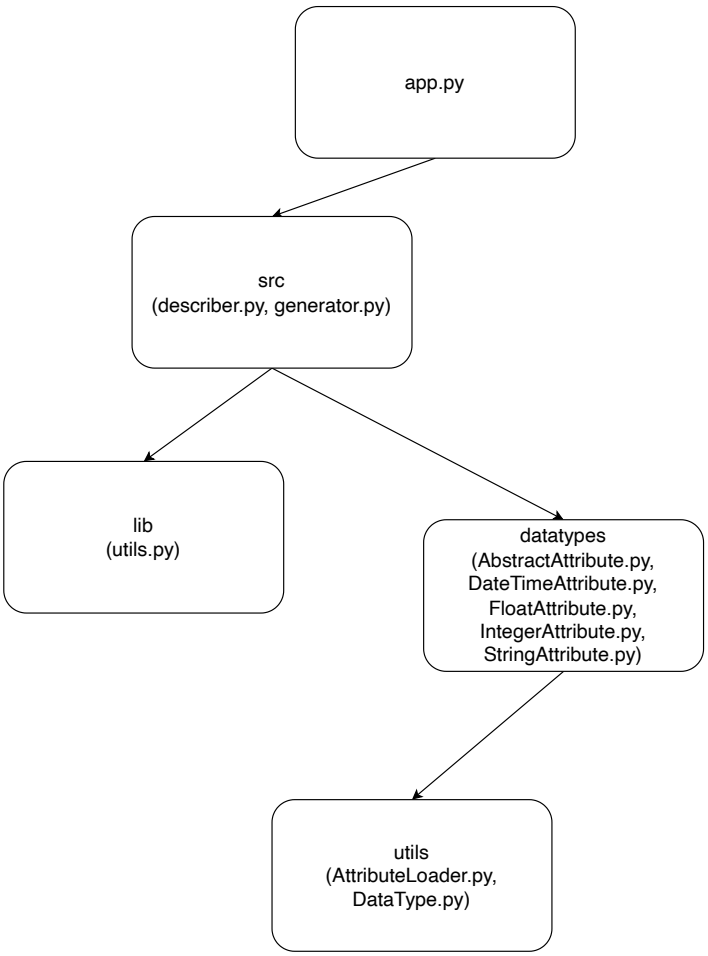


Рисунок 3.1 – Диаграмма модулей

3.3 Основные модули

Модуль src

Модуль src содержит реализацию алгоритма построения Байесовской сети с дифференциальной приватностью и отвечает за построение синтетических данных на основе ее структуры.

Класс Describer реализует методы:

— init — конструктор класс, к котором инициализируются атрибуты класса;

— describe_dataset — описывает датасет с использованием байесовской сети;

— read_dataset_from_csv — загружает датасет из CSV-файла;

— infer_attribute_data_types — определяет типы данных атрибутов;

— analyze_dataset_meta — анализирует метаинформацию датасета (ключи, категориальность и т.д.);

— is_categorical — определяет, является ли атрибут категориальным;

— represent_input_dataset_by_columns — представляет входной датасет в виде объектов-атрибутов;

— inject_laplace_noise_into_distribution_per_attribute — добавляет лапласовский шум в распределения атрибутов;

— encode_dataset_into_binning_indices — кодирует датасет в индексы бинов для построения байесовской сети.

— save_dataset_description_to_file — сохраняет описание датасета в файл.

Класс Generator реализует методы:

— init — онструктор класса. Инициализирует атрибуты экземпляра;

— generate_dataset — Генерирует синтетический датасет с учетом зависимостей между атрибутами;

— save_synthetic_data — Сохраняет сгенерированный синтетический датасет в файл;

— get_sampling_order — Возвращает порядок выборки атрибутов на основе структуры байесовской сети;

Модуль lib

Модуль lib содержит вспомогательные функции для работы модуля src. В данном модуле реализованы функции:

— calculate_sensitivity — вычисляет чувствительность для построения байесовской сети;

— calculate_delta — вычисляет параметр delta для применения дифференциальной приватности;

— calculate_k — вычисляет максимальную степень при построении байесовской сети;

— greedy_bayes — строит байесовскую сеть с помощью жадного алгоритма;

— exponential_mechanism — реализует экспоненциальный механизм для выбора структуры сети с учетом параметра приватности;

— set_random_seed — станавливает фиксированное значение seed для генераторов случайных чисел;

— mutual_information — вычисляет взаимную информацию между двумя распределениями (Series/DataFrame), используя mutual_info_score из sklearn;

— pairwise_attributes_mutual_information — вычисляет нормализованную взаимную информацию для всех пар признаков;

— normalize_given_distribution — нормализует переданный массив частот (преобразует в вероятностное распределение) и обрабатывает отрицательные и бесконечные значения;

— read_json_file — читает и возвращает содержимое JSON-файла.

3.4 Формат входных и выходных данных

Входные данные

Входными данными для разработанного методы являются:

1. датасет с исходными данными — CSV-файл с названиями атрибутов в формате на листинге 3.1:

Листинг 3.1 – Реализация алгоритма для построения БС с дифференциальной приватностью

```
age,education,sex,relationship,marital-status,income
19,HS-grad,Female,Not-in-family,Never-married,<=50K
35,HS-grad,Female,Unmarried,Never-married,<=50K
36,Bachelors,Male,Husband,Married-civ-spouse,>50K
40,Assoc-acdm,Male,Not-in-family,Divorced,>50K
36,Masters,Male,Husband,Married-civ-spouse,>50K
30,11th,Male,Husband,Married-civ-spouse,<=50K
44,Bachelors,Male,Husband,Married-civ-spouse,<=50K
37,Assoc-acdm,Male,Husband,Married-civ-spouse,>50K
36,Prof-school,Male,Not-in-family,Never-married,<=50K
50,10th,Male,Husband,Married-civ-spouse,<=50K
40,HS-grad,Male,Own-child,Never-married,<=50K
24,Some-college,Female,Own-child,Married-civ-spouse,<=50K
40,HS-grad,Female,Not-in-family,Never-married,<=50K
38,5th-6th,Male,Husband,Married-civ-spouse,<=50K
60,9th,Female,Not-in-family,Widowed,<=50K
```

2. настройки приватности — числовой параметр ϵ, который учитывется при добавлении шума;

3. количество генерируемых записей — числовой параметр, который учитывается непосредственно при генерации синтетических данных;

4. категориальные атрибуты — строковый параметр, в котором через запятую перечисляются названия атрибутов, являющихся категориальными;

5. количество родительских узлов — параметр, который учитывается при построении Байесовской сети.

Выходные данные

Результатом работы методы являются синтетические данные с обеспечением дифференциальной приватности в формате CSV-файа и с заданным количеством записей.

3.5 Тестирование программного обеспечения

Методика тестирования

Тестирование реализованного программного обеспечения проводилось в комплексном формате и включало в себя типы тестов: модульное тестирование — метод тестирования, при котором проверяется корректности работы отдельных компонентов программы в изоляции от остальных частей системы; функциональное тестирование — метод тестирования, при котором проверяется корректноая работа системы в целом.

Результаты тестирования

Результаты тестирования показали корректность работы разработанного метода для различных входных данных. Были протестированы следующие аспекты:

— Загрузка датасета из файла;

— Анализизирование датасета;

— Создание структуры Байесовской сети;

— Добавление шума;

— Генерация синтетических данных;

— Сохранение выходных данных.

Все тесты были пройдены успешно.

3.6 Пример использования программного обеспечения

Интерфейс пользователя приложения представлен на рисунке 3.2. В интерфейсе присутствуют поля для ввода данных, также многие поля изначальная заполнены данными по умлчанию.

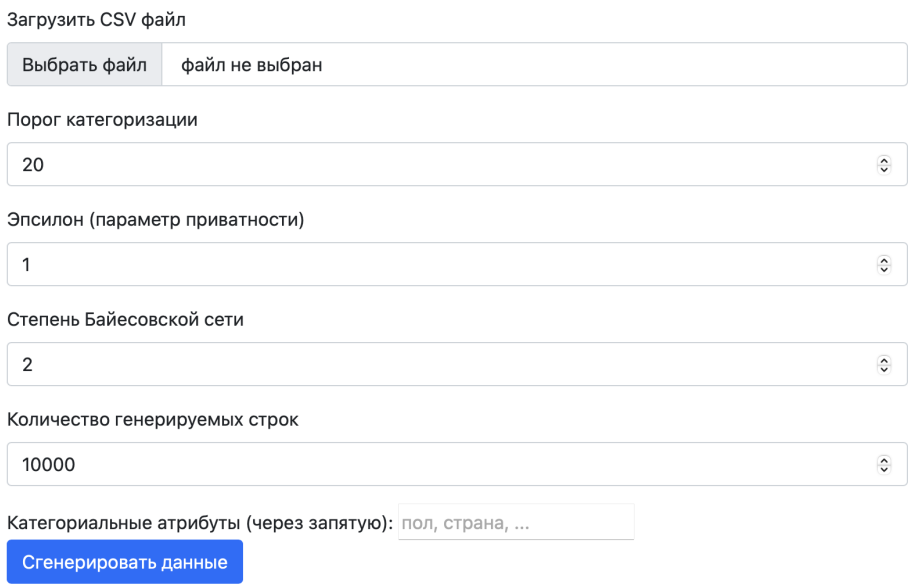


Рисунок 3.2 – Реализация пользовательского интерфейса

4 Исследовательская часть

4.1 Методика исследования

Для оценки эффективности разработанного метода обеспечение дифференциальной приватности при генерации синтетических данных. Исследование включало в себя измерение следующих характеристик:

— время работы метода при различных размерах данных;

4.2 Исследование характеристик метода при различных входных параметрах

4.2.1 Время работы

Одной из ключевых характеристик реализованного метода является зависимость время работы от разных входных параметров.

Для исследования данной зависимости были проведены измерения времени работы для:

1. исходных датасетов разного размера количества записей при одинаковых других входных параметров (параметр приватности — 1, степень БС — 2);

2. исходных датасетов разного размера количества атрибутов при одинаковых других входных параметров (параметр приватности — 1, степень БС — 2);

3. разных параметров приватности при одинаковых других входных параметров (размера датасета — 1000 строк, степень БС — 2);

4. разных степенях БС при одинаковых других входных параметров (размера датасета — 1000 строк, параметр приватности — 1).

На рисунке 4.1 представлена диаграмма зависимости времени работы от размера количества записей входного датасета:

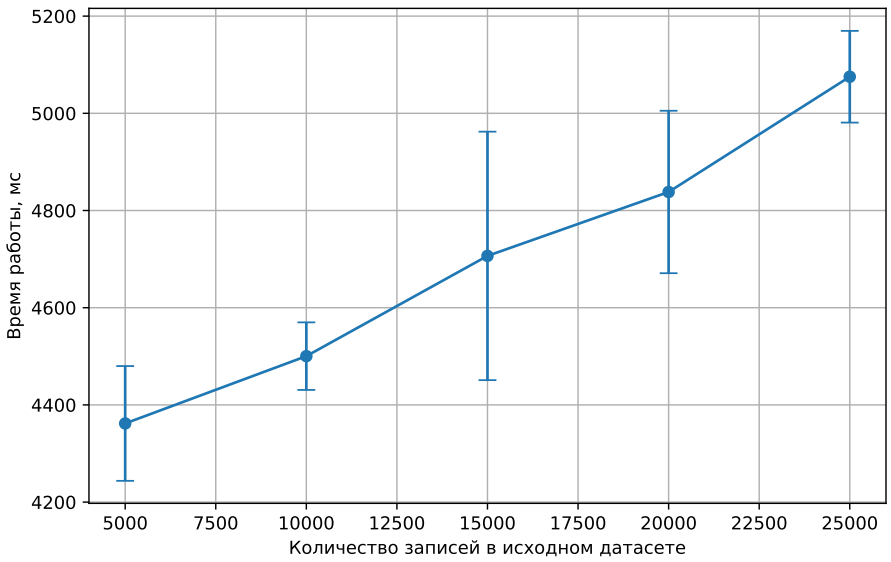


Рисунок 4.1 – Зависимость времени работы от размера количества записей входного датасета

Результаты измерений показывают, что: время работы увеличивается вместе с количеством записей в датасет; наблюдается линейная зависимость.

На рисунке 4.2 представлена диаграмма зависимости времени работы программы от размера количества атрибутов входного датасета:

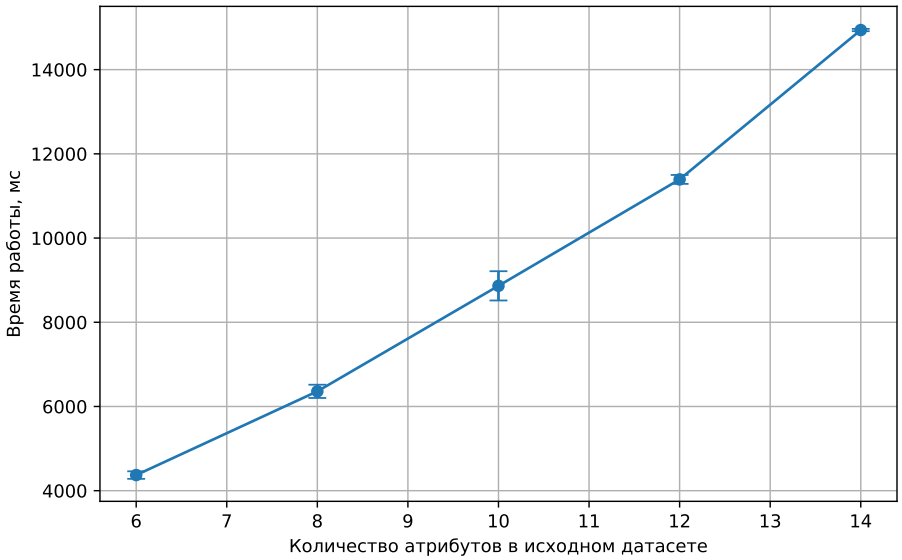


Рисунок 4.2 – Зависимость времени работы программы от размера количества атрибутов входного датасета

Результаты измерений показывают, что: время работы увеличивается вместе с количеством атрибутов в датасета; наблюдается линейная зависимость.

Также из двух диаграмм видно, что при увеличении количества атрибутов на выполнение работы уходит больше времени, чем при увеличении количества записей.

На рисунке 4.3 представлена диаграмма зависимости времени работы от разных параметров приватности при одинаковых других входных параметрах:

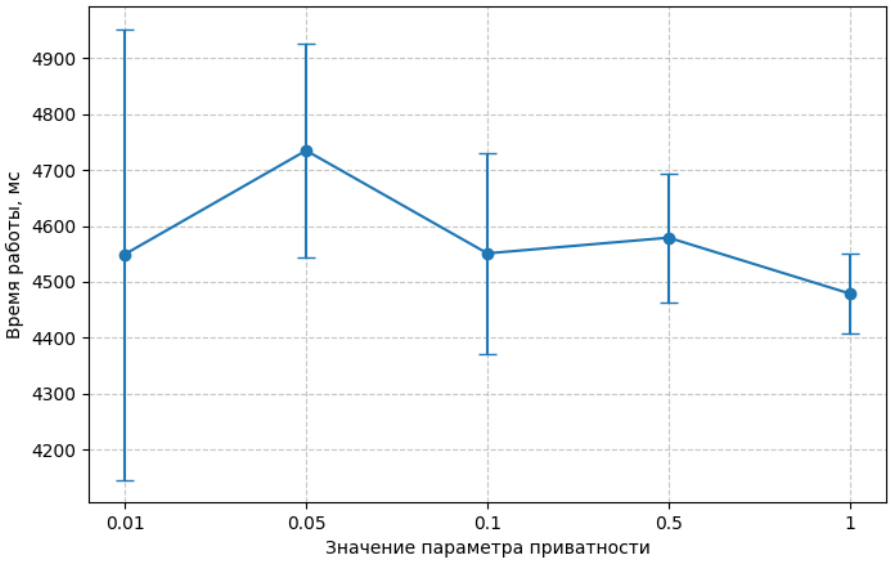


Рисунок 4.3 – Зависимость времени работы от разных параметров приватности

На рисунке 4.4 представлена диаграмма зависимости времени работы от степени Байесовской сети:

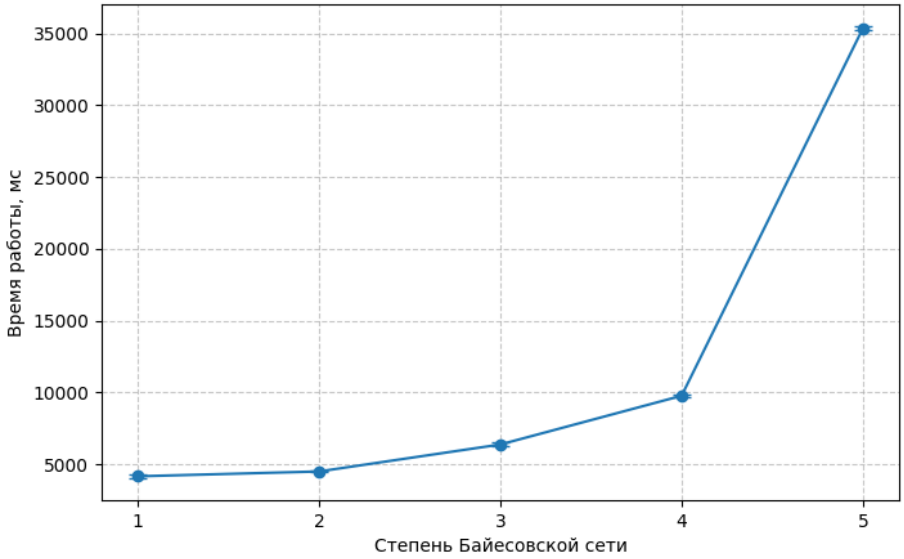


Рисунок 4.4 – Зависимость времени работы от степени Байесовской сети

4.2.2 Коэффициенты корреляции

Средняя абсолютная ошибка (англ. mean absolute error сокр. MAE) — оценка качества результата, которая оценивает среднее отклонение синтетических корреляций от реальных. Данная оценка будет использоваться в качестве критерия при изменении степени Байесовской сети.

На рисунке 4.4 представлена диаграмма зависимости MAE от степени Байесовской сети:

Для исследования данной зависимости были проведены измерения для:

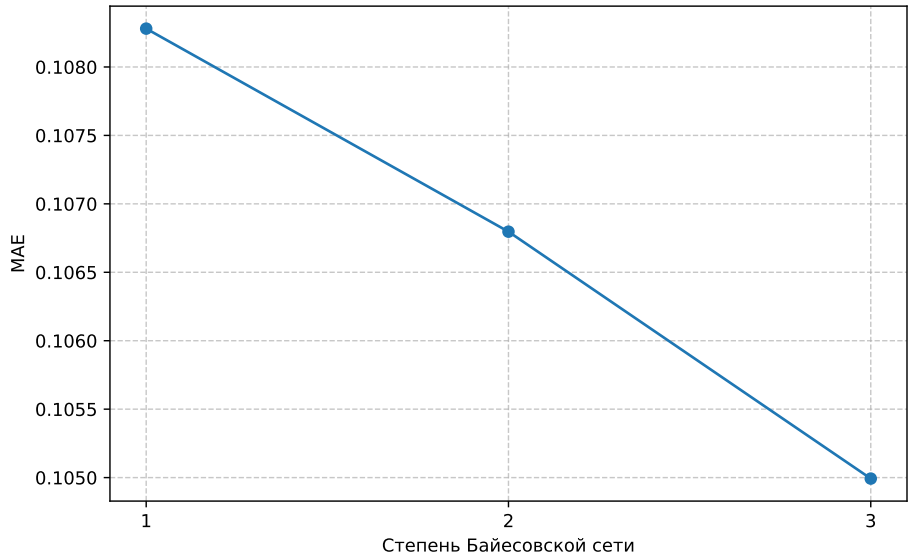


Рисунок 4.5 – Зависимость MAE от степени Байесовской сети